学校代码：10285

学　　号：20225232026

苏州大学

SOOCHOW UNIVERSITY

硕士学位论文

（专业学位）

基于机器学习的肝硬化合并脓毒血症患者的亚组识别及其预后分析

Machine Learning-Driven Subphenotype Identification and Prognostic Analysis in Cirrhotic Patients with Sepsis

研究生姓名　林嘉希

指导教师姓名　朱锦舟

专业名称　105101 内科学

研究方向　机器学习于消化疾病领域应用

所在院部　苏州大学附属第一医院

论文提交日期　2025 年 5 月

苏州大学学位论文独创性声明

本人郑重声明：所提交的学位论文是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含其他个人或集体已经发表或撰写过的研究成果，也不含为获得苏州大学或其它教育机构的学位证书而使用过的材料。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人承担本声明的法律责任。

论文作者签名：_____日　期：_____

苏州大学学位论文使用授权声明

本人完全了解苏州大学关于收集、保存和使用学位论文的规定，即：学位论文著作权归属苏州大学。本学位论文电子文档的内容和纸质论文的内容相一致。苏州大学有权向国家图书馆、中国社科院文献信息情报中心、中国科学技术信息研究所（含万方数据电子出版社）、中国学术期刊（光盘版）电子杂志社送交本学位论文的复印件和电子文档，允许论文被查阅和借阅，可以采用影印、缩印或其他复制手段保存和汇编学位论文，可以将学位论文的全部或部分内容编入有关数据库进行检索。

涉密论文□

本学位论文属　　在_____年___月解密后适用本规定。

非涉密论文■

论文作者签名：_____日　期：_____

导 师 签 名：_____日　期：_____

基于机器学习的肝硬化合并脓毒血症患者的亚组识别及其预后分析

中文摘要

背景：肝硬化合并脓毒血症患者的病理生理机制复杂且具有高度异质性，常伴随多器官功能衰竭，预后通常较差。目前关于该患者群体的研究多基于小样本数据，并依赖传统的回归统计学方法，尚无研究利用机器学习算法深入探究其临床亚组特征及预后差异。

方法：本研究是一项回顾性多中心研究，整合了以下三个队列的数据：MIMIC-IV（Medical Information Mart for Intensive Care-IV）、eICU-CRD（eICU Collaborative Research Database）以及苏州队列（基于苏州大学附属第一医院重症医学科 2016-2023 年间收治的患者信息）。首先，采用无监督学习算法 k-prototypes，基于患者入院 24 小时内的数据（包括人口统计学信息、重要生命体征、实验室检查结果及既往病史），识别肝硬化合并脓毒血症患者的亚型，并通过重复聚类方法评估患者在第 3 天和第 10 天的亚组转变情况以验证时间维度一致性。其次，通过多因素 Cox 回归分析评估各亚组的预后差异，主要终点指标为 ICU（Intensive Care Unit）死亡率，次要终点包括 7 天和 28 天 ICU 死亡率。进一步探讨入院前三日白蛋白输注策略对不同亚组预后的影响，采用多因素 Cox 回归初步评估每日白蛋白输注与亚组预后的关系，并基于 Logistic 回归的倾向性评分匹配算法矫正混杂因素后验证干预措施的稳定性。最后，开发、验证并在线部署了一种肝硬化合并脓毒血症亚组早期预测模型：将 MIMIC-IV 队列随机分为训练集和内部验证集（比例为 7:3），eICU-CRD 队列作为外部验证集，苏州队列数据用于真实世界测试集。通过信息熵筛选和递归特征消除算法筛选变量，基于随机森林、极限梯度提升等 8 种不同的机器学习算法训练，并采用基于交叉验证的随机超参数搜索策略识别最优算法及其最佳超参数组合。此外，针对模型可解释性分析，采用 SHAP（Shapley Additive Explanations）、Breakdown 及 PDP（Partial Dependence Plot）算法对最佳模型进行全局和局部解释，并揭示预测变量对结果的交互作用。

结果：共计 4478 名纳入研究，其中 MIMIC-IV 队列患者 3998 名，eICU-CRD 队列患者 406 名，苏州队列 76 名。基于 k-prototypes 算法，共识别出三个预后不同的亚组。亚组 1 具有最高的 ICU 死亡率（MIMIC-IV 队列为 56%，eICU-CRD 队列为 36%），以严重的内环境紊乱及多脏器损伤为特点，被定义为高危组。亚组 2 及亚组 3 具有逐渐降低的死亡率，故被分为中危组和低危组。中危组和低危组拥有相较高危组明显改善的肝肾功能，但低危组患者的凝血功能优于中危组患者。基于校准人口信息学、既往病史、实验室检查指标等协变量的多因素 Cox 回归模型，低危组的 ICU 死亡风险显著低于高危组（MIMIC-IV 队列中 HR [Hazard Ratio] = 0.22，95%置信区间 0.17 - 0.28，$p < 0.001$；eICU-CRD 队列中 HR = 0.37，95%置信区间 0.20 - 0.69，$p < 0.001$）。经多因素 Cox 回归及倾向性评分分析，高危组患者第二日及第三日输注白蛋白对预后有明显保护作用。经变量筛选，红细胞比容、INR（International Normalized Ratio）、阴离子间隙、肌酐和总胆红素被纳入构建亚组早期预测模型。随机森林算法具有综合最佳表现（宏平均受试者操作特征曲线下面积平均数为 0.93，宏布里尔评分平均数为 0.32），被选择构建最终预测模型并在线部署（网址：http://39.101.122.171:3838/App3/）。基于 SHAP 算法发现升高的阴离子间隙对高危组患者，以及红细胞比容对中危组和低危组分组的全局贡献。Breakdown 算法实现了个体患者分组预测概率的分布累加。PDP 算法则指处了阴离子间隙等变量数值变化对最终预测亚组的影响。

结论：

1）本研究发现三种预后不同的亚组，高危组具有严重的内环境紊乱及多脏器损伤。中危组及低危组的内环境紊乱及脏器损伤较高危组明显改善，且无明显差异，但中危组患者的凝血功能劣于低危组患者。

2）入院第二日及第三日输注白蛋白对高危组患者预后具有显著保护作用。中危组及低危组未发现早期输注白蛋白益处。

3）研究基于红细胞比容、INR、阴离子间隙、肌酐和总胆红素变量构建、验证并在线部署了亚组早期预测模型。

关键词：聚类分析，机器学习，肝硬化，脓毒血症

作　　者：林嘉希

指导老师：朱锦舟

Machine Learning-Driven Subphenotype Identification and Prognostic Analysis in Cirrhotic Patients with Sepsis

Abstract

Background The pathophysiological mechanisms in patients with liver cirrhosis complicated by sepsis are complex and highly heterogeneous, often accompanied by multiple organ failure, with generally poor prognosis. Current research on this patient population is predominantly based on small sample data and relies on traditional regression statistical methods. No studies to date have utilized machine learning algorithms to thoroughly explore the clinical subphenotype characteristics and prognostic differences in these patients.

Methods This study is a retrospective multicenter investigation that integrated data from three cohorts: MIMIC-IV (Medical Information Mart for Intensive Care-IV), eICU-CRD (eICU Collaborative Research Database), and the Suzhou cohort (based on patient information from the Department of Critical Care Medicine at the First Affiliated Hospital of Soochow University between 2016-2023). First, an unsupervised learning algorithm, k-prototypes, was employed to identify subphenotypes of patients with liver cirrhosis complicated by sepsis, based on data collected within 24 hours of admission (including demographic information, vital signs, laboratory test results, and medical history). The temporal consistency of these subphenotypes was validated by assessing patient transitions between subphenotypes on days 3 and 10 using repeated clustering methods. Second, multivariate Cox regression analysis was used to evaluate prognostic differences among the subphenotypes. The primary endpoint was ICU (Intensive Care Unit) mortality, with secondary endpoints including 7-day and 28-day ICU mortality. The study further explored the impact of albumin infusion strategies during the first three days of admission on the prognosis of different subphenotypes. This was preliminarily assessed using multivariate Cox regression to evaluate the relationship between daily albumin infusion and subphenotype outcomes, followed by validation of intervention stability after adjusting for confounding factors using propensity score matching based on logistic regression. Finally, an early prediction model for subphenotypes of liver cirrhosis

complicated by sepsis was developed, validated, and deployed online. The MIMIC-IV cohort was randomly divided into training and internal validation sets (7:3 ratio), the eICU-CRD cohort served as an external validation set, and the Suzhou cohort data was used as a real-world test set. Variables were selected through information entropy screening and recursive feature elimination algorithms. Eight different machine learning algorithms, including Random Forest and Extreme Gradient Boosting, were trained, and the optimal algorithm with its best hyperparameter combination was identified using a random hyperparameter search strategy based on cross-validation. Additionally, for model interpretability analysis, SHAP (Shapley Additive Explanations), Breakdown, and PDP (Partial Dependence Plot) algorithms were applied to provide global and local explanations of the best model and to reveal the interaction effects of predictor variables on outcomes.

Results A total of 4478 patients were included in the study, comprising 3998 patients from the MIMIC-IV cohort, 406 patients from the eICU-CRD cohort, and 76 patients from the Suzhou cohort. Based on the k-prototypes algorithm, three distinct subphenotypes with different prognoses were identified. Subphenotype 1, classified as the high-risk subphenotype, exhibited the highest ICU mortality rate (56% in the MIMIC-IV cohort and 36% in the eICU-CRD cohort), characterized by severe dysregulation of the internal environment and multiple organ damage. Subphenotypes 2 and 3 demonstrated progressively lower mortality rates and were categorized as medium-risk and low-risk subphenotypes, respectively. The medium-risk and low-risk subphenotypes showed significantly improved hepatic and renal function compared to the high-risk subphenotype, while the low-risk subphenotype patients exhibited better coagulation function than those in the medium-risk subphenotype. Using a multivariate Cox regression model adjusted for covariates including demographics, medical history, and laboratory indicators, the low-risk subphenotype demonstrated significantly lower ICU mortality risk compared to the high-risk subphenotype (HR [Hazard Ratio] = 0.22, 95% confidence interval 0.17 - 0.28, $p < 0.001$ in the MIMIC-IV cohort; HR = 0.37, 95% confidence interval 0.20 - 0.69, $p < 0.001$ in the eICU-CRD cohort). After multivariate Cox regression and propensity score analysis, albumin infusion on the second and third days showed significant protective effects on outcomes in high-risk subphenotype patients. Following variable screening, hematocrit, INR (International Normalized Ratio), anion gap, creatinine, and total bilirubin were included in the construction of an early prediction model for subphenotypes. The

Random Forest algorithm demonstrated the best overall performance (with a macro-average area under the receiver operating characteristic curve of 0.93 and a macro-average Brier score of 0.32) and was selected to build the final prediction model, which was deployed online (accessible at: http://39.101.122.171:3838/App3/). Based on the SHAP (Shapley Additive Explanations) algorithm, elevated anion gap was identified as a significant global contributor to the classification of high-risk patients, while hematocrit contributed to the classification of medium-risk and low-risk subphenotypes. The Breakdown algorithm enabled the cumulative distribution of prediction probabilities for individual patient grouping. The PDP (Partial Dependence Plot) algorithm illustrated how changes in variable values, such as anion gap, influenced the final predicted subphenotype.

Conclusion

1)This study identified three subphenotypes with distinct prognoses. The high-risk subphenotype was characterized by severe internal environment dysregulation and multiple organ damage. The medium-risk and low-risk subphenotypes demonstrated significantly improved internal environment regulation and organ function compared to the high-risk subphenotype, with no significant differences between these two subphenotypes, except that patients in the medium-risk subphenotype exhibited poorer coagulation function than those in the low-risk subphenotype.

2)Albumin infusion on the second and third days of admission demonstrated significant protective effects on outcomes for patients in the high-risk subphenotype. No benefits of early albumin infusion were observed in the medium-risk and low-risk subphenotypes.

3)An early prediction model for subphenotypes was developed, validated, and deployed online based on five variables: hematocrit, INR (International Normalized Ratio), anion gap, creatinine, and total bilirubin.

Keywords Cluster Analysis, Machine Learning, Liver Cirrhosis, Septicemia

Written by: Jiaxi Lin

Supervised by: Jinzhou Zhu

目　录

前　言 **1**
材料与方法 **2**
1．研究队列 2
2．纳入与排除标准 4
3．临床变量纳入与预处理 5
4．基于无监督聚类分析的肝硬化合并脓毒血症患者的亚组识别 5
5．肝硬化合并脓毒血症患者的亚组分类纵向一致性 6
6．肝硬化合并脓毒血症患者亚组预后分析 6
7．白蛋白早期输注策略对肝硬化合并脓毒血症亚组患者预后分析 6
8．基于机器学习算法的早期亚组识别模型建立验证与部署 7
9．数据分析 10
结　果 **11**
1．研究队列 11
2．基于无监督聚类分析的肝硬化合并脓毒血症患者的亚组识别 17
3．肝硬化合并脓毒血症患者的亚组分类纵向一致性 23
4．肝硬化合并脓毒血症患者识别亚组预后分析 28
5．白蛋白早期输注策略对肝硬化合并脓毒血症亚组患者预后分析 32
6．基于机器学习算法的早期亚组识别与预后模型建立验证与部署 35
讨　论 **47**
结　论 **50**
参考文献 **51**
综　述 **55**
参考文献 62
中英文术语和缩略语对照表 **67**
攻读学位期间公开发表的文章 **69**
致　谢 **71**

前 言

肝硬化是慢性肝病终末期的表现，其核心特征为肝实质结构损害（肝细胞弥漫性变性坏死、肝内血管新生、肝脏纤维组织大量增生及假小叶形成）和门脉高压症候群[1]。根据 2023 年全球疾病负担研究，全球肝硬化患者（代偿及失代偿）总人数已达 1.22 亿，给全球卫生健康系统带来了沉重负担[2]。肝硬化病因分布呈现显著地域差异：亚洲以乙型肝炎病毒感染为主，而欧美国家则以酒精性肝病和代谢功能障碍相关脂肪性肝病（Metabolic Dysfunction-Associated Steatotic Liver Disease，MASLD）为主要诱因[2]。值得注意的是，近年来随着肥胖流行，MASLD 相关肝硬化发病率年增长率达 6.8%，预计将成为未来十年肝硬化首要病因[2,3]。

脓毒血症是一种由患者对感染的反应失调引发的危及生命的器官功能障碍[4]。在肝硬化疾病进程中，脓毒血症是一个常见且严重的并发症[5]。既往研究发现，肝硬化患者因存在肠道屏障功能障碍、网状内皮系统吞噬能力下降及补体系统失调，导致其脓毒血症发生率较普通人群升高 3 - 5 倍[6–8]。更为严峻的是，合并脓毒血症可使肝硬化患者死亡率跃升至 70%[9]。因此，准确识别与预测肝硬化合并脓毒血症患者的危险分层与预后情况，对合理安排医疗资源，改善预后，具有重要意义。

目前针对肝硬化患者危险分层与预后的评分系统及模型，包括 Child-Pugh 评分和 MELD 系列评分系统，虽然在临床实践中广泛使用，但在面对肝硬化合并脓毒血症这一特殊患者群体时，仍存在以下不足：1）既往评分系统与模型主要侧重于评估肝硬化整体的严重程度，而对于合并脓毒血症患者预后的异质性识别能力不足。2）既往研究基于监督学习，依赖明确的数据结局标签，可能无法充分挖掘潜在的亚组模式或隐含的疾病进展规律。3）既往模型大多基于传统回归统计方法构建，而近年来机器学习技术在数据驱动为核心的预测模型中展现出更佳表现，能够更高效地处理复杂数据并提高预测精度[10–12]。

鉴于此，本研究旨在利用无监督聚类分析对肝硬化合并脓毒血症患者的亚组进行精准识别，并对预后及治疗方式影响进行深入分析。同时进一步采用机器学习算法，构建肝硬化合并脓毒血症患者早期亚组识别模型，助力临床应用。通过跨数据库多中心分析与方法学的改进，本研究旨在准确地识别患者亚组危险分层，为临床医生提供更有力的决策支持工具，从而改善肝硬化合并脓毒血症患者的治疗管理。

材料与方法

本研究的整体思路围绕“临床发现-治疗影响-实际应用”的主线展开，分为三个主要部分：1）基于无监督聚类分析的肝硬化合并脓毒血症患者的亚组识别；2）针对不同亚组患者的治疗策略分析；3）基于机器学习算法构建亚组早期识别模型。本研究主要流程图见**图 1**。下文为具体研究细节。

1．研究队列

本研究为一项多中心回顾性研究，数据分析基于三个独立队列：1）数据库开发队列：MIMIC-IV（Medical Information Mart for Intensive Care-IV）队列：该队列由位于美国波士顿的以色列女执事医疗中心 ICU（Intensive Care Unit）建立，涵盖了 73181 名患者的入院及治疗信息[13]。2）数据库验证队列：eICU-CRD（eICU Collaborative Research Database）队列：该队列整合了美国多家医疗中心 ICU 患者的临床诊疗数据，并经过去身份化处理，共计包含 200859 名患者的信息[14]。3）真实世界验证队列：苏州队列：该队列基于苏州大学附属第一医院重症医学科 2016-2023 年收治患者信息。MIMIC-IV 队列和 eICU-CRD 队列的数据使用均经 PhysioNet 审批授权，批准号为 48533840；苏州队列的研究方案已通过苏州大学附属第一医院伦理委员会审批，批准号为 2024022。

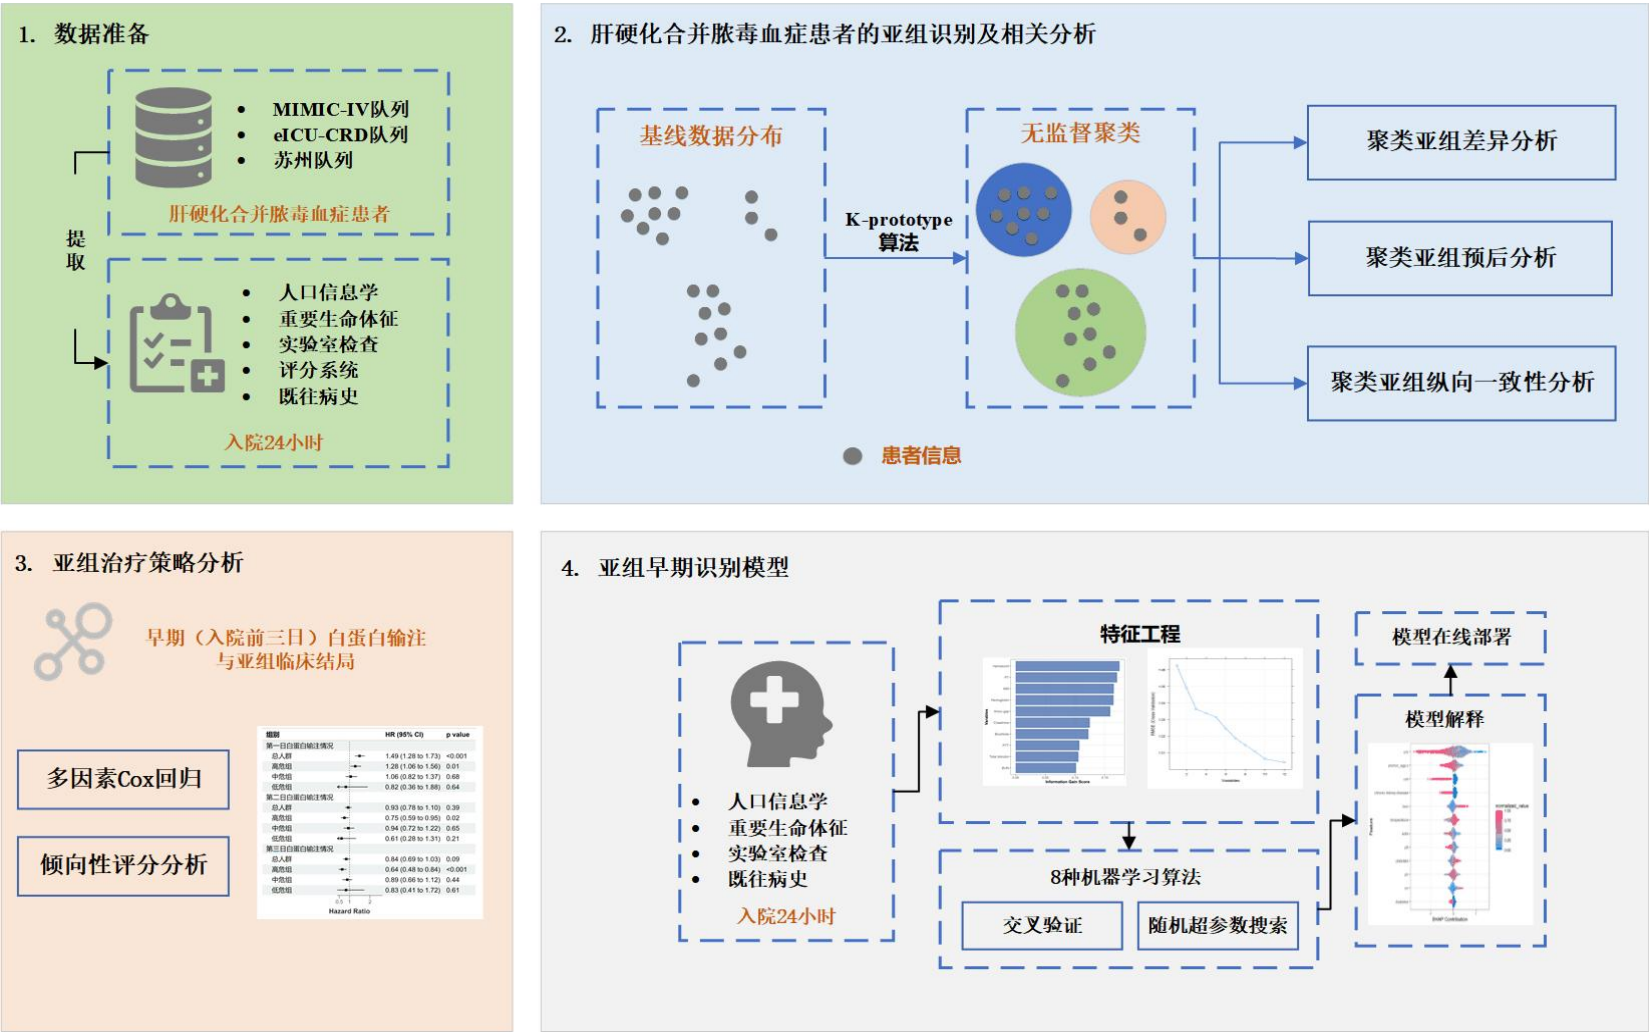

图 1 研究主要流程示意图

2．纳入与排除标准

2.1．纳入标准

1）患者均为首次入住 ICU 且年龄大于 18 周岁。

2）患者存在肝硬化病史，肝硬化诊断基于 ICD（International Classification of Diseases）- 9/10 诊断编码（**表 1**）。

表 1 肝硬化诊断 ICD-9/10 编码

诊断编码版本	诊断编码	定义
ICD-10	K70.3	酒精性肝硬化
	K71.7	中毒性性肝病伴有肝纤维化和肝硬化
	K74	肝纤维化和肝硬变
	K74.1	肝硬化
	K74.2	肝纤维化伴有肝硬化
	K74.3	原发性胆汁性肝硬化
	K74.4	继发性胆汁性肝硬化
	K74.5	未特指的胆汁型肝硬变
	K74.6	其他和未特指的肝硬变
	P78.803	先天性肝硬化
ICD-9	571.2	酒精性肝硬化
	571.5	肝硬化，未提及酒精性者
	571.6	胆道性肝硬化

3）患者入院 24 小时内被诊断为脓毒血症，诊断标准为 Sepsis-3.0 标准[15]。具体而言，标准要求患者有明确的感染证据或高度怀疑感染，且序贯器官衰竭评分（Sequential Organ Failure Assessment，SOFA）≥ 2 分。

2.2．排除标准

1）患者入院后生存时间小于 24 小时。

2）患者基线数据严重缺乏（数据缺乏比例大于 30%）。

3．临床变量纳入与预处理

本研究主要研究结局为 ICU（Intensive Care Unit）死亡率，次要结局为 7 天 ICU 死亡率与 28 天 ICU 死亡率。研究所纳入基线数据均为患者入院 24 小时内所收集，包括：1）人口信息学信息：年龄、性别、体重（千克）。2）重要生命体征：心率（次/分钟）、呼吸频率（次/分钟）、体温（摄氏度）、收缩压（毫米汞柱）、舒张压（毫米汞柱）。3）实验室检查：pH 值、氧分压（毫米汞柱）、二氧化碳分压（毫米汞柱）、红细胞比容（%）、血红蛋白（g/dL）、血小板（10^9/L）、白细胞计数（10^9/L）、白蛋白（g/dL）、阴离子间隙（mmol/L）、碳酸氢盐（mmol/L）、尿素氮（mg/dL）、钙离子（mg/dL）、氯离子（mmol/L）、肌酐（mg/dL）、葡萄糖（mg/dL）、钠离子（mmol/L）、钾离子（mmol/L）、淋巴细胞计数（10^9/L）、国际标准化比值（International Normalized Ratio，INR）、凝血酶原时间（秒）、部分凝血活酶时间（秒）、丙氨酸转氨酶（U/L）、天门冬氨酸氨基转移酶（U/L）、碱性磷酸酶（U/L）、总胆红素（mg/dL）。4）评分系统：格拉斯哥昏迷评分(Glasgow Coma Scale，GCS)、SOFA、急性生理评分Ⅲ（Simplified Acute Physiology Score III，APSIII）。5）既往病史：心肌梗死、充血性心力衰竭、痴呆、慢性阻塞性肺疾病、风湿性疾病、糖尿病、肾脏疾病、恶性肿瘤，AIDS（Acquired Immunodeficiency Syndrome）。6）治疗方式：早期白蛋白输注。研究纳入临床变量均不存在过量缺失（变量缺失率均小于 30%），且对变量缺失值采用多重插补法进行填补。

4．基于无监督聚类分析的肝硬化合并脓毒血症患者的亚组识别

本聚类分析基于患者入院基线数据。该数据包含数值型和分类型数据，故采用 K-prototypes 无监督聚类算法识别肝硬化合并脓毒血症患者亚组[16]。K-prototypes 算法聚类大致过程如下：1）使用欧几里得距离度量样本间数值型数据的距离；2）通过匹配系数计算分类型数据间的距离；3）通过适当的权重系数对这两种距离进行加权求和，继而得出最终样本间距离，实现混合数据类型的聚类分析。在聚类过程中，为避免数值型数据不同单位量纲所致聚类结果偏移，标准化被用于数值型数据聚类预处理。在确定最佳聚类数量时，基于误差平方和（Sum of Squared Errors，SSE）的肘方法（Elbow Method）被采用进行数量选择。该方法通过绘制 SSE 随聚类数变化的曲线，选择曲线拐点对应的聚类数作为最优解，从而在模型复杂度与聚类效果之间取得

平衡。在聚类结果可视化方面，采用 UMAP（Uniform Manifold Approximation and Projection）算法。该方法是一种高效的非线性降维技术，能够在保留局部结构的同时，揭示高维数据中的全局模式[17]。通过 UMAP 投影，可将患者的临床特征映射到二维空间中，呈现不同亚组的空间分布特征。

5．肝硬化合并脓毒血症患者的亚组分类纵向一致性

K-prototypes 算法为基于特征相似性的横断面聚类分析方法，在纵向时间维度上的亚组一致性分析存在局限性。为探究肝硬化合并脓毒症患者亚组的动态演变，评估亚组患者在时间维度一致性。本研究于 MIMIC-IV 队列中采用多时点重复聚类策略，即分别在入院后第 3 日（免疫激活阶段）及第 10 天（免疫重塑及器官功能转归阶段）进行重复聚类分析（聚类方法参照上文亚组识别）。为进一步直观呈现患者亚组在病程中的动态转化特征，本研究构建了桑基图（Sankey Diagram）对亚组间的转化路径进行可视化展示。

6．肝硬化合并脓毒血症患者亚组预后分析

累计死亡率曲线用于初步分析各亚组预后差异，并采用 Log-rank 检验用于亚组间生存差异显著性检验。为进一步探讨亚组与临床结局之间的关联，研究构建了多因素 Cox 比例风险模型。为确保结果的稳健性，研究逐步调整了多个潜在混杂因素，具体建模过程如下：1）模型 1：调整年龄与性别，以控制人口学特征对预后的影响；2）模型 2：在模型 1 的基础上进一步纳入既往病史（包括糖尿病、高血压等），以校正患者的基础健康状况；3）模型 3 ：在模型 2 的基础上再次调整实验室检查指标（包含肝功能指标、炎症标志物等），以全面反映患者的生理状态及其对预后的潜在影响。使用 Schoenfeld 残差检验 Cox 模型等比例风险假设，对于不满足等比例风险假设模型，通过引入时间依赖性协变量构建扩展 Cox 模型，提高对复杂生存数据的拟合能力。

7．白蛋白早期输注策略对肝硬化合并脓毒血症亚组患者预后分析

肝硬化合并脓毒血症患者入院阶段常伴血流动力学不稳定，胶体渗透压降低及低白蛋白血症[18]。研究表明，白蛋白输注在液体复苏阶段具有潜在价值，特别是在逆转脓毒血症诱导的低血压方面表现出积极作用[19–21]。基于此背景，旨在探讨早期（入院

前三日）白蛋白输注策略对肝硬化合并脓毒血症不同亚组人群预后的影响，以期为优化差异人群的治疗策略提供依据。本研究基于 MIMIC-IV 队列数据展开分析。患者的白蛋白输注量通过累计计算 25%白蛋白（数据库编码：220862）与 5%白蛋白（数据库编码：220864）的输注总量得出。

在评估白蛋白输注对预后影响时，首先采用多因素 Cox 回归模型，在调整基础人口学变量（年龄和性别）的基础上，初步分析白蛋白输注与否对不同亚组人群预后的影响。随后，为进一步控制混杂因素，采用基于鲁宾因果模型理论的倾向性评分匹配进行分析。倾向性评分的计算基于 Logistic 回归模型，纳入的协变量包括亚组患者的人口学信息（年龄和性别）以及部分关键实验室指标（白蛋白水平、总胆红素、INR、肌酐）。倾向性评分匹配时，以第一日、第二日和第三日白蛋白输注与否作为匹配的干预措施。在匹配过程中，采用卡钳匹配法，卡钳值为 0.2，设置匹配比率为 1:1。标准均值差（Standardized Mean Difference, SMD）被采用评估匹配后协变量差异，以确保匹配队列的分布均衡。利用匹配后的队列再次评估白蛋白输注与否对不同亚组人群预后的影响，从而进一步验证结果的稳健性。研究所采用的多因素 Cox 回归结果以森林图形式可视化。

8．基于机器学习算法的早期亚组识别模型建立验证与部署

利用机器学习算法，基于患者入住 ICU 临床基线变量，开发亚组早期识别模型。在数据集划分方面，MIMIC-IV 队列被随机分为训练集和内部验证集，比例为 7:3，以确保模型的初步构建与内部验证的独立性；eICU-CRD 队列则作为外部验证集。此外，苏州队列数据被用作真实世界测试集，旨在模拟模型在真实临床环境中的应用场景。具体而言，即模拟在对患者亚组情况未知的前提下，利用早期亚组识别模型预测患者的亚组分类，并进一步比较不同亚组间的预后差异，从而验证模型在实际应用中的可行性和有效性。

模型特征工程流程如下：1）基于信息增益的过滤法进行变量初筛。信息增益被定义为变量对分类结局进行预测时减少不确定性的评价指标。在本研究中，当变量的信息熵大于或等于 0.1 时，认为该变量对提高预测性能具有显著贡献，并将其初步筛选出来。2）初筛变量相关性分析：高度相关的变量可能对模型的预测性能及可解释性产生负面影响。因此，本研究采用斯皮尔曼相关系数对初筛变量进行相关性检验。

若两变量之间的相关性系数大于或等于 0.6，则认为它们存在高度相关性。在此基础上，结合信息熵数据，剔除冗余变量，从而优化特征集。3）最佳变量组合筛选：为了进一步确定最优特征组合，本研究采用递归特征消除（Recursive Feature Elimination，RFE）算法，通过迭代增加或移除变量来评估不同变量组合对预测性能的影响。模型性能的评估标准包括准确性和 Kappa 系数。最终，选择准确性与 Kappa 系数最高的变量组合作为模型的输入特征。

8 种不同的机器学习算法，包括线性判别分析（Linear Discriminant Analysis，LDA）、二次判别分析（Quadratic Discriminant Analysis，QDA）、朴素贝叶斯（Naive Bayes，NB）、K 近邻（k-nearest neighbor，KNN）、决策树（Decision Tree，DT）、随机森林（Random Forest，RF）、极限梯度提升（Extreme Gradient Boosting，Xgboost）和支持向量机（Support Vector Machine，SVM），于训练集中进行模型训练。

在训练过程中，首先利用随机搜索方法在 5 折交叉验证的框架下对各机器学习算法的超参数进行优化，最多评估 20 个超参数组合以找到最优值；随后，将调优后的各算法超参数通过 10 折交叉验证全面评估性能。各算法调整超参数及调整范围见**表 2**。于 10 折交叉验证表现最优算法中选取最优超参数组合构建预测模型。本模型为多类别分类任务，采用准确率（Accuracy）和宏曲线下面积（Macro Area Under Curve，Macro AUC）来评估模型的区分能力宏布里尔评分（Macro Brier Score）用于评估模型预测概率与实际结果的一致性。本研究采用的多分类宏指标计算，通过单一分类对其余分类的计算策略，即对于任一分类，将其视为正类，其余类别视作负类，从而转化为二分类指标计算问题。此外，通过混淆矩阵对模型的具体分类结果进行可视化分析，进一步显示模型在各类别上的分类表现。

为增强机器学习模型的临床可解释性，本研究采用了多种先进的可解释性算法，从全局和个体层面分析模型的决策依据。1）全局解释：SHAP（Shapley Additive exPlanations）算法：SHAP 算法基于博弈论中的 Shapley 值，计算每个变量对模型输出的边际贡献，从而实现全局变量重要性排序。2）个体预测解释：Breakdown 算法：对于个体患者的预测结果，本研究采用 Breakdown 算法，通过调整变量的重要性系数逐步分解预测结果，从而实现对单个样本预测的透明化解释。这种方法有助于临床医生理解模型如何根据特定患者的特征得出预测结论。3）变量依赖关系分析：部分依赖图（Partial Dependence Plots, PDP）：为探索选定变量与预测结局之间的非线性关系，

本研究绘制了部分依赖图。PDP 展示了在控制其他变量不变的情况下，某一变量的变化如何影响模型的预测结果，从而帮助研究人员更直观地理解变量的作用机制。

为提高模型临床应用，本研究实现了亚组预测模型的在线部署。

表 2 机器学习算法超参数选择及超参数调整范围

算法名称	调整超参数及范围
线性判别分析	无
二次判别分析	无
朴素贝叶斯	数值稳定性，范围（10^{-6},10^{-3}） 普拉斯平滑强度，范围（0,1）
K 近邻	最近邻数量，范围（1，20）
决策树	节点分裂所需最小样本，范围（1，25） 叶节点所需最小样本，范围（1，15） 复杂度参数，范围（0，0.05） 树的最大深度，范围（3，10）
随机森林	每棵树分裂时特征数，范围（3，10） 树的最大深度，范围（5，20） 树数量，范围（100，500）
极限梯度提升	子节点最小样本权重，范围（1，10） 样本采样比例，范围（0.6，1） 特征采样比例，范围（0.6，1） 迭代次数，范围（50，200） 学习率，范围（0.01，0.3） 树最大深度，范围（3，10）
支持向量机	核函数，范围（Linear, Polynomial, Radial, Sigmoid） 多项式核的阶数，范围（2，5） 正则化参数 C，范围（0.1，100） 核函数参数，范围（0.1，10）

9．数据分析

本研究数据分析均基于 R 语言（版本：4.2.0）。无监督聚类分析采用 cluster 包（版本：2.1.8），机器学习模型建立采用 mlr3 包（版本 0.23.0），模型部署采用 Shiny 包（版本：1.10.0）。在数据分布检验方面，采用 Kolmogorov-Smirnov 检验评估数值型数据是否符合正态分布。对于数值型数据的描述性统计，依据其分布特性分别采用以下方式：对于符合正态分布的数据，使用平均数（标准差）进行描述；对于不符合正态分布的数据，则采用中位数（第 25 百分位数，第 75 百分位数）进行描述。对于分类变量，采用频率（百分比）的形式进行描述。在队列间数据差异分析中，对于符合正态分布且方差齐性的数值型数据，采用独立样本 t 检验；若数据不符合正态分布或方差不齐，则采用非参数秩和检验。对于分类数据，依据样本量大小，采用卡方检验或 Fisher 确切概率法进行分析。所有统计检验均为双尾检验，显著性水平设定为 0.05，即当双尾 p 值小于 0.05 时认为差异具有统计学意义。

结 果

1．研究队列

本研究共纳入来自三个独立队列的患者共计 4478 名，其中 MIMIC-IV 队列患者 3998 名（3085 名存活，913 名死亡），eICU-CRD 队列患者 406 名（310 名存活，96 名死亡），苏州队列 73 名（50 名存活，23 名死亡）。MIMIC-IV 队列患者与 eICU-CRD 队列患者筛选流程见**示意图 2**。

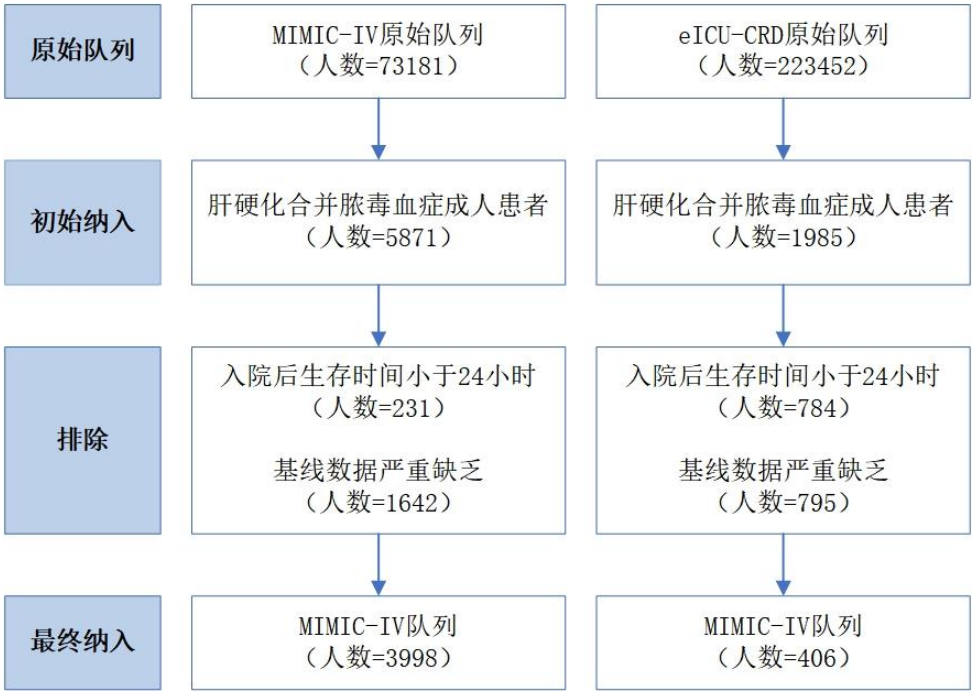

示意图 2 MIMIC-IV 队列与 eICU-CRD 队列患者筛选示意图

研究所纳入各队列基线数据汇总于**表 3**。三个队列中，性别在存活组与死亡组间的分布差异均不显著，均呈现男性占比高于女性。体重在 MIMIC-IV 队列中呈现显著差异，即死亡组患者体重偏大，但于其余两队列中均未见差异。各队列死亡组普遍存在更差的内环境与代谢状态（如更低的白蛋白、pH 值、碳酸氢盐，更高的 INR、总胆红素、尿素氮等），MIMIC-IV 和苏州队列差异尤为显著（多数 $p < 0.001$）。同时，各队列死亡组的 SOFA、APSIII 评分均显著高于存活组（所有队列 $p < 0.001$），提示患者病情更加危重。绝大部分既往病史并未于存活组与死亡组之间出现显著差异，仅糖尿病既往病史于 MIMIC-IV 队列中显示差异（$p < 0.001$）。

表 3 研究纳入队列基线数据汇总

基线变量	MIMIC-IV 队列			eICU-CRD 队列			苏州队列		
	存活（人数=3085）	死亡（人数=913）	*p*	存活（人数=310）	死亡（人数=96）	*p*	存活（人数=50）	死亡（人数=23）	*p*
人口信息学信息									
性别			0.631			0.982			0.432
女性	1085 (35.17%)	329 (36.04%)		132 (42.50%)	41 (42.71%)		20 (40%)	7 (30.43%)	
男性	2000 (64.83%)	584 (63.96%)		178 (57.50%)	55 (57.29%)		30 (60%)	16 (69.57%)	
年龄	60 (52, 67)	61 (53, 70)	0.014	58.15 (12.39)	57.33 (9.56)	0.472	68 (56, 76)	60 (50, 70)	0.051
体重（千克）	80 (69, 97)	83 (70, 100)	0.022	79 (65, 97)	82 (70, 103)	0.213	67 (60, 76)	72 (65, 76)	0.634
重要生命体征									
心率（次/分钟）	73 (62, 84)	77 (65, 90)	<0.001	93.87 (20.59)	94.42 (19.36)	0.912	80 (74, 97)	84 (78, 108)	0.120
收缩压（毫米汞柱）	111 (103, 123)	104 (97, 114)	<0.001	112 (98, 130)	110 (97, 126)	0.342	98 (90, 110)	98 (86, 105)	0.724
舒张压（毫米汞柱）	61 (55, 68)	57 (51, 63)	<0.001	63 (56, 70)	59 (49, 66)	0.010	62 (55, 68)	62 (53, 66)	0.412
呼吸频率（次/分钟）	18.10 (15.90, 21)	20.20 (17.40, 23.40)	<0.001	20 (16, 24)	20 (18, 24)	0.363	18 (15, 20)	18 (16, 21.80)	0.391
体温（摄氏度）	36.83 (36.61, 37.09)	36.67 (36.35, 36.96)	<0.001	36.40 (36.02, 36.80)	36.05 (35.15, 36.50)	<0.001	36.80 (36.50, 37.18)	36.85 (36.50, 37.18)	0.951
实验室检查									
pH 值	7.38 (7.33, 7.42)	7.35 (7.28, 7.40)	<0.001	7.35 (7.29, 7.43)	7.27 (7.14, 7.36)	<0.001	7.42 (7.28, 7.44)	7.21 (7.02, 7.39)	0.120
氧分压（毫米汞柱）	98 (62, 169)	95 (64, 144)	0.224	89 (72, 122)	91 (71, 118)	0.973	95 (69, 128)	109 (71, 149)	0.926

基线变量	MIMIC-IV 队列			eICU-CRD 队列			苏州队列		
	存活（人数=3085）	死亡（人数=913）	*p*	存活（人数=310）	死亡（人数=96）	*p*	存活（人数=50）	死亡（人数=23）	*p*
二氧化碳分压（毫米汞柱）	40 (34, 45)	38 (33, 44)	0.002	35 (29, 41)	37 (31, 43)	0.520	39 (33, 43)	37 (30, 41)	0.254
红细胞比容（%）	28.80 (25.40, 32.90)	27.10 (24.30, 31.60)	<0.001	30.95 (7.48)	30.05 (7.05)	0.365	32 (24, 37)	23 (19, 32)	0.042
血红蛋白（g/dL）	9.50 (8.30, 10.90)	9 (8, 10.35)	<0.001	10.34 (2.57)	10.08 (2.39)	0.338	10.40 (8, 12.10)	7.70 (6.10, 10.40)	0.010
血小板计数（10^9/L）	113 (74, 174)	99 (63, 160)	<0.001	109 (71, 177)	98 (61, 140)	0.040	94 (65, 136)	61 (42, 112)	<0.001
白细胞计数（10^9/L）	9 (6, 13)	12 (8, 17)	<0.001	13 (8, 18)	12 (8, 19)	0.728	9 (6, 14)	14 (5, 18)	0.417
白蛋白（g/dL）	3.05 (2.60, 3.50)	2.80 (2.40, 3.30)	<0.001	2.40 (2, 2.90)	2.20 (1.78, 2.80)	0.009	2.94 (2.61, 3.29)	2.76 (2.49, 3.14)	0.004
阴离子间隙（mmol/L）	15 (12.50, 17.50)	17.50 (14.50, 21)	<0.001	12 (9, 16)	14 (11, 19)	0.014	12 (10, 15)	19 (14, 24)	0.007
碳酸氢盐（mmol/L）	22.50 (19.50, 25)	20 (16.50, 23.50)	<0.001	20.83 (6.15)	19.16 (6.03)	0.013	20.20 (18, 23.80)	18.80 (12.90, 23.50)	0.785
尿素氮（mg/dL）	25 (16, 41)	38 (22, 60)	<0.001	30 (16, 47)	33 (19, 50)	0.326	11 (7, 17)	13 (9, 25)	0.254
钙离子（mg/dL）	8.25 (7.75, 8.75)	8.35 (7.75, 9)	0.001	8.30 (7.70, 8.80)	8.05 (7.60, 8.72)	0.110	7.8 (7.16, 8.44)	8.16 (7.36, 8.88)	0.336
氯离子（mmol/L）	103 (98, 107)	101 (96, 106)	<0.001	102 (97, 107)	102 (97, 108)	0.964	104 (100, 107)	103 (100, 107)	0.726
肌酐（mg/dL）	1.15 (0.80, 2)	1.80 (1.10, 2.95)	<0.001	1.58 (0.93, 2.86)	1.79 (1.18, 3.03)	0.110	1.03 (0.69, 1.63)	1.65 (0.83, 2.57)	0.010
葡萄糖（mg/dL）	129 (107, 168)	126 (104, 159)	0.009	118 (96, 154)	104 (75, 138)	0.001	120.7 (90, 140.4)	138.6 (102.6, 165.6)	0.213
钠离子（mmol/L）	137 (134, 140)	136 (132, 141)	0.008	135 (130, 140)	135 (131, 140)	0.723	136 (134, 141)	137 (133, 143)	0.918
钾离子（mmol/L）	4.20 (3.80, 4.70)	4.30 (3.80, 4.85)	<0.001	4.00 (3.60, 4.70)	4.15 (3.60, 4.70)	0.757	4.10 (3.89, 4.55)	4.21 (3.77, 4.78)	0.829
INR	1.55 (1.30, 1.95)	2.10 (1.65, 2.60)	<0.001	1.60 (1.30, 2.20)	2 (1.60, 2.73)	<0.001	1.41 (1.27, 1.63)	1.77 (1.29, 2.44)	0.037

基线变量	MIMIC-IV 队列			eICU-CRD 队列			苏州队列		
	存活（人数=3085）	死亡（人数=913）	*p*	存活（人数=310）	死亡（人数=96）	*p*	存活（人数=50）	死亡（人数=23）	*p*
凝血酶原时间（秒）	17 (14, 21)	22 (18, 28)	<0.001	19 (16, 24)	22 (18, 30)	<0.001	17 (15, 19)	22 (16, 28)	0.030
部分凝血活酶时间（秒）	36 (31, 45)	47 (37, 62)	<0.001	37 (32, 43)	41 (33, 51)	0.020	39 (32, 44)	46 (39, 65)	0.010
丙氨酸转氨酶（U/L）	32 (19, 68)	38 (22, 76)	<0.001	36 (22, 58)	40 (26, 65)	0.275	32 (16, 62)	25 (16, 112)	0.868
碱性磷酸酶（U/L）	106 (75, 160)	120 (84, 196)	<0.001	130 (91, 197)	122 (82, 183)	0.254	99 (79, 136)	95 (50, 142)	0.426
天门冬氨酸氨基转移酶（U/L）	61 (36, 130)	87 (46, 194)	<0.001	63 (43, 116)	92 (56, 161)	0.002	45 (25, 87)	77 (38, 124)	0.110
总胆红素（mg/dL）	2 (1, 4)	5 (2, 13)	<0.001	3 (1, 6)	6 (3, 10)	<0.001	2 (1, 4)	4 (2, 9)	0.050
评分系统									
GCS	15 (14, 15)	14 (13, 15)	<0.001	15 (13, 15)	13 (8, 15)	<0.001	15 (14, 15)	14 (9, 15)	<0.001
SOFA	7 (5, 10)	11 (8, 14)	<0.001	7 (5, 9)	11 (7, 15)	<0.001	6 (4, 9)	13 (7, 15)	<0.001
APSIII	50 (39, 65)	76 (61, 94)	<0.001	63 (48, 80)	88 (68, 113)	<0.001	55 (50, 68)	93 (77, 124)	<0.001
既往病史									
心肌梗死			0.143			0.568			0.568
无	2789 (90.40%)	840 (92%)		298 (96.13%)	91 (94.79%)		49 (98%)	22 (95.65%)	
有	296 (9.60%)	73 (8%)		12 (3.87%)	5 (5.21%)		1 (2%)	1 (4.35%)	
充血性心力衰竭			0.964			0.477			0.792
无	2495 (80.87%)	739 (80.94%)		280 (90.31%)	89 (92.71%)		40 (80%)	19 (82.61%)	

基线变量	MIMIC-IV 队列			eICU-CRD 队列			苏州队列		
	存活（人数=3085）	死亡（人数=913）	*p*	存活（人数=310）	死亡（人数=96）	*p*	存活（人数=50）	死亡（人数=23）	*p*
痴呆	有	590 (19.13%)	174 (19.06%)	0.765	30 (9.69%)	7 (7.29%)	0.557	10 (20%)	4 (17.39%)	0.331
	无	3051 (98.99%)	904 (99.01%)		304 (98.06%)	95 (98.96%)		48 (96%)	23 (100%)	
慢性阻塞性肺疾病	有	34 (1.01%)	9 (0.99%)	0.147	6 (1.94%)	1 (1.04%)	0.882	2 (4%)	0 (0%)	0.331
	无	2334 (75.66%)	712 (77.98%)		273 (88.06%)	84 (87.5%)		48 (96%)	23 (100%)	
风湿性疾病	有	751 (24.34%)	201 (22.02%)	0.675	37 (11.04%)	12 (12.5%)	0.774	2 (4%)	0 (0%)	0.945
	无	3035 (98.38%)	900 (98.68%)		302 (97.42%)	93 (96.87%)		48 (96%)	22 (95.65%)	
糖尿病	有	50 (1.62%)	13 (1.32%)	0.013	8 (2.58%)	3 (3.13%)	0.140	2 (4%)	1 (4.35%)	0.400
	无	2044 (66.26%)	645 (71%)		218 (70%)	75 (78%)		39 (78%)	16 (70%)	
肾脏疾病	有	1041 (33.74%)	268 (29%)	0.178	92 (30%)	21 (22%)	0.495	11 (22%)	7 (30%)	0.860
	无	2280 (74%)	695 (76.12%)		255 (82.26%)	76 (79.17%)		45 (90%)	21 (91.30%)	
	有	805 (26%)	218 (23.88%)		55 (17.74%)	20 (20.83%)		5 (10%)	2 (8.70%)	

基线变量	MIMIC-IV 队列			eICU-CRD 队列			苏州队列		
	存活（人数=3085）	死亡（人数=913）	*p*	存活（人数=310）	死亡（人数=96）	*p*	存活（人数=50）	死亡（人数=23）	*p*
恶性肿瘤			0.395			0.568			0.882
无	2699 (87.49%)	789 (86.42%)		278 (89.68%)	88 (91.67%)		42 (84%)	19 (82.61%)	
有	386 (12.51%)	124 (13.58%)		32 (10.32%)	8 (8.33%)		8 (16%)	4 (17.39%)	
AIDS			0.364			0.235			不适用
无	3031 (98.25%)	901 (98.69%)		310 (100%)	95 (98.96%)		50 (100%)	23 (100%)	
有	54 (1.75%)	12 (1.31%)		0 (0%)	1 (1.04%)		0 (0%)	0 (0%)	
住院时间 (天)	2.70 (1.60, 5.20)	4.20 (2, 8.70)	<0.001	3.20 (1.70, 7)	4.50 (1.60, 9.80)	0.326	12 (6, 21)	6 (3, 11)	0.020

2．基于无监督聚类分析的肝硬化合并脓毒血症患者的亚组识别

考虑到苏州队列人数较少，根据既往经验法则，样本量至少是变量数的 5-10 倍，聚类结果缺乏稳定性，故无监督聚类分析基于 MIMIC-IV 队列与 eICU-CRD 队列。通过肘方法（**图 3**）确定最佳聚类亚组数，结果表明，在两个队列中，SSE 曲线均于聚类数 3 处显示转折点，提示最佳聚类亚组数均为 3。

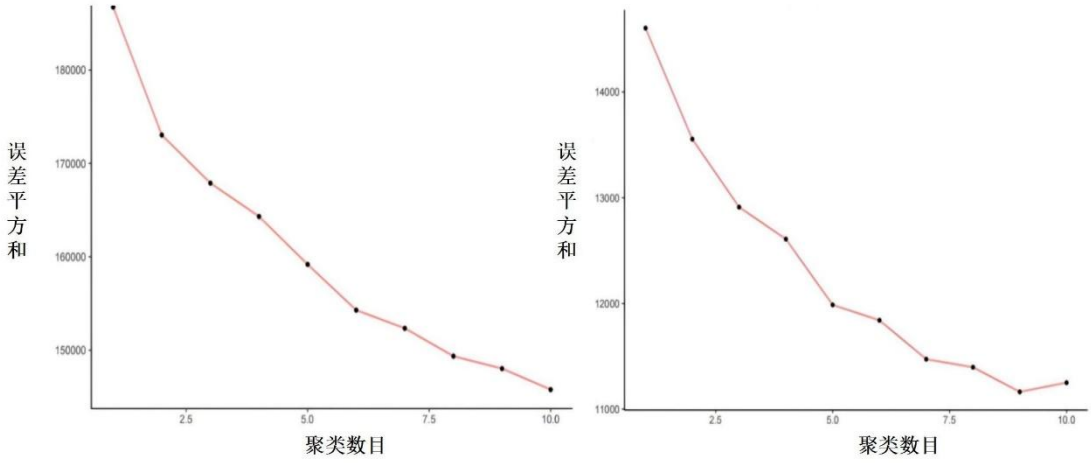

图 3 基于肘方法的 SSE 图显示最佳聚类亚组数目

注：左图为 MIMIC-IV 队列，右图为 eICU-CRD 队列。

基于 UMAP 算法的聚类结果可视化（**图 4**）进一步验证了这一发现。两队列患者数据被降维可视化于二维空间，均被分为 3 个不同着色亚组。MIMIC 队列数据亚组聚类相对紧密，eICU-CRD 队列数据边界较模糊，存在部分重叠和混合。

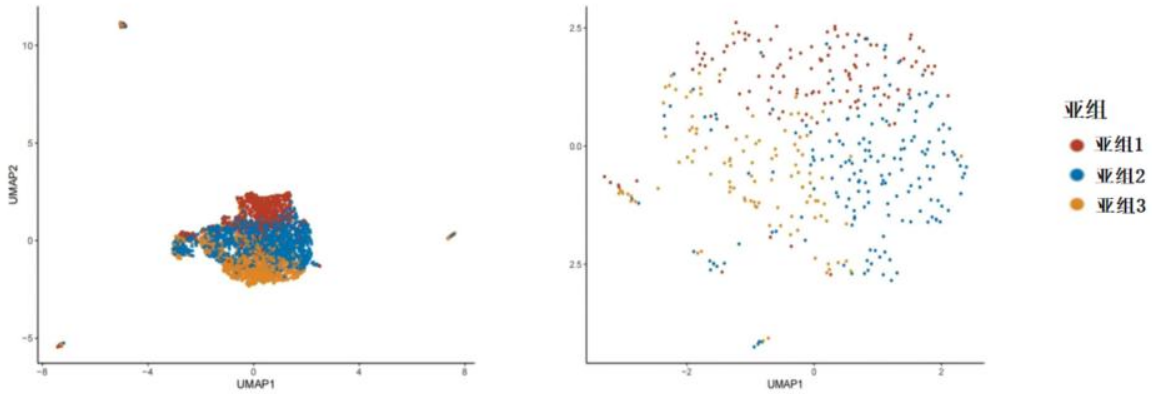

图 4 基于 UMAP 算法聚类亚组可视化

注：左图为 MIMIC-IV 队列，右图为 eICU-CRD 队列。

各队列中聚类亚组的基线特征汇总见**表 4**。各亚组在基线数据上表现出显著差异。在 MIMIC-IV 队列和 eICU-CRD 队列中，被分类为亚组 1 的患者呈现出明显的内环境紊乱和多器官功能损伤。具体而言，亚组 1 患者的酸中毒表现尤为显著（MIMIC-IV 队列中 pH 值中位数为 7.31，eICU-CRD 队列中 pH 值中位数为 7.28）。此外，其肝脏损伤指标（如丙氨酸转氨酶和天门冬氨酸氨基转移酶）均显著高于其他亚组，提示严重的肝功能损害。这些患者还面临较高的出血风险，表现为 INR、凝血酶原时间 PT 和部分凝血活酶时间显著升高。肾功能损伤也是亚组 1 患者的重要特征，其血清肌酐水平在 MIMIC-IV 队列中的中位数为 2.55 mg/dL，在 eICU-CRD 队列中则进一步升高至 2.87 mg/dL。

对于分类为亚组 2 和亚组 3 的患者，内环境紊乱（如 pH 值和阴离子间隙）以及器官损伤指标（如丙氨酸转氨酶、天门冬氨酸氨基转移酶和肌酐）在两队列中未表现出一致趋势。然而，凝血相关指标（如 INR、凝血酶原时间和部分凝血活酶时间）显示，亚组 2 患者的凝血功能差于亚组 3 患者，这可能成为区分两者的潜在临床因素。

表 4 肝硬化合并脓毒血症患者亚组基线数据汇总

基线数据	MIMIC-IV 队列				eICU-CRD 队列			
	亚组 1（人数=820）	亚组 2（人数=1860）	亚组 3（人数=1318）	*p*	亚组 1（人数=122）	亚组 2（人数=173）	亚组 3（人数=111）	*p*
人口信息学信息								
性别				<0.001				<0.001
女性	280 (34.15%)	734 (39.46%)	400 (30.35%)		22 (18.03%)	120 (69.36%)	31 (27.93%)	
男性	540 (66.85%)	1,126 (60.54%)	918 (69.65%)		100 (81.97%)	53 (30.64%)	80 (72.07%)	
年龄	58 (51, 67)	61 (53, 69)	60 (53, 67)	<0.001	55 (48, 64)	56 (51, 63)	63 (55, 72)	<0.001
体重（千克）	85 (73, 102)	79 (66, 93)	83 (70, 99)	<0.001	83 (72, 101)	74 (61, 90)	85 (72, 110)	<0.001
重要生命体征								
心率（次/分钟）	77 (65, 90)	74 (63, 85)	72 (62, 83)	<0.001	91 (77, 102)	99 (83, 112)	93 (80, 106)	0.004
收缩压（毫米汞柱）	104 (98, 113)	106 (100, 115)	121 (110, 134)	<0.001	106 (95, 117)	113 (98, 129)	114 (102, 132)	0.003
舒张压（毫米汞柱）	55 (50, 61)	58 (53, 64)	67 (60, 75)	<0.001	88 (79, 103)	97 (82, 111)	95 (84, 110)	0.002
呼吸频率（次/分钟）	20.30 (17.60, 23.70)	18.40 (16, 21.30)	17.90 (15.90, 20.60)	<0.001	19 (16, 24)	21 (17, 26)	19 (16, 22)	0.004
体温（摄氏度）	36.63 (36.33, 36.89)	36.80 (36.58, 37.06)	36.89 (36.67, 37.18)	<0.001	36.15 (34.70, 36.50)	36.40 (35.94, 36.70)	36.60 (36.35, 36.90)	<0.001
实验室检查								
pH 值	7.31 (7.24, 7.38)	7.38 (7.34, 7.43)	7.38 (7.34, 7.42)	<0.001	7.28 (7.21, 7.35)	7.35 (7.26, 7.42)	7.36 (7.29, 7.42)	0.330
氧分压（毫米汞柱）	100 (67, 154)	86 (53, 140)	117 (71, 202)	<0.001	82 (70, 108)	87 (70, 132)	99 (81, 118)	0.216
二氧化碳分压（毫米汞柱）	38 (32, 43)	38 (34, 44)	41 (37, 46)	<0.001	32 (27, 41)	36 (30, 41)	40 (31, 47)	0.047
红细胞比容（%）	27 (23.90, 31.40)	26.40 (24.10, 29.10)	32.90 (29.60, 36.70)	<0.001	27 (24, 33)	29 (25, 34)	34 (29, 38)	<0.001

基线数据	MIMIC-IV 队列				eICU-CRD 队列			
	亚组 1（人数=820）	亚组 2（人数=1860）	亚组 3（人数=1318）	*p*	亚组 1（人数=122）	亚组 2（人数=173）	亚组 3（人数=111）	*p*
血红蛋白（g/dL）	9 (7.90, 10.31)	8.65 (7.80, 9.65)	10.90 (9.81, 12.15)	<0.001	9.35 (8, 10.88)	10 (8.30, 11.60)	10.90 (9.70, 12.70)	<0.001
血小板计数（10^9/L）	94 (60, 146)	112 (71, 180)	117 (78, 170)	<0.001	104 (64, 176)	101 (61, 163)	121 (80, 176)	0.041
白细胞计数（10^9/L）	13 (8, 19)	9 (6, 14)	8 (6, 12)	<0.001	16 (11, 24)	12 (7, 17)	11 (8, 16)	<0.001
白蛋白（g/dL）	2.95 (2.50, 3.46)	2.80 (2.45, 3.20)	3.25 (2.85, 3.60)	<0.001	2.20 (1.90, 2.60)	2.30 (1.80, 2.60)	2.80 (2.30, 3.30)	<0.001
阴离子间隙（mmol/L）	20.50 (17.50, 24.50)	14.50 (12.50, 17)	14 (12, 16)	<0.001	16 (12, 24)	12 (9, 15)	13 (9, 16)	<0.001
碳酸氢盐（mmol/L）	17.50 (14.50, 21)	21.50 (19, 24.50)	23.50 (21.50, 26)	<0.001	17 (13, 21)	21 (18, 25)	22 (20, 26)	<0.001
尿素氮（mg/dL）	50 (31, 77)	28 (18, 44)	20 (13, 30)	<0.001	46 (29, 79)	22 (12, 37)	32 (18, 44)	<0.001
钙离子（mg/dL）	8.45 (7.75, 9.10)	8.15 (7.70, 8.65)	8.35 (7.90, 8.80)	<0.001	8.10 (7.60, 8.78)	8.10 (7.50, 8.60)	8.70 (8.15, 9.20)	<0.001
氯离子（mmol/L）	99 (94, 104)	102 (98, 107)	104 (100, 108)	<0.001	98 (92, 104)	106 (101, 111)	100 (94, 106)	<0.001
肌酐（mg/dL）	2.55 (1.65, 4.05)	1.28 (0.85, 2.15)	0.95 (0.70, 1.30)	<0.001	2.87 (1.78, 4.03)	1.08 (0.79, 1.78)	1.57 (1.06, 2.57)	<0.001
葡萄糖（mg/dL）	132 (106, 176)	124 (104, 152)	136 (111, 182)	<0.001	102 (75, 130)	114 (92, 136)	152 (112, 208)	<0.001
钠离子（mmol/L）	135 (131, 140)	136.20 (132.50, 139.50)	138.50 (136, 141)	<0.001	132 (127, 136)	137 (133, 141)	134 (130, 140)	<0.001
钾离子（mmol/L）	4.55 (4, 5.15)	4.15 (3.75, 4.70)	4.15 (3.85, 4.55)	<0.001	4.50 (3.83, 5.45)	3.80 (3.40, 4.30)	4.20 (3.75, 4.80)	<0.001
INR	2.35 (1.90, 3.05)	1.65 (1.40, 2.05)	1.35 (1.20, 1.60)	<0.001	2.20 (1.70, 2.98)	1.74 (1.40, 2.30)	1.40 (1.20, 1.70)	<0.001
凝血酶原时间（秒）	25 (20, 33)	18 (15, 22)	15 (13, 17)	<0.001	24 (19, 31)	19 (16, 25)	16 (14, 19)	<0.001
部分凝血活酶时间（秒）	52 (41, 68)	38 (32, 47)	33 (29, 39)	<0.001	42 (36, 54)	37 (31, 43)	33 (29, 40)	<0.001
丙氨酸转氨酶（U/L）	51 (26, 137)	29 (18, 51)	34 (21, 81)	<0.001	50 (31, 100)	32 (21, 49)	33 (24, 50)	<0.001
碱性磷酸酶（（U/L）	113 (79, 171)	115 (82, 185)	99 (71, 145)	<0.001	140 (100, 237)	115 (85, 169)	129 (92, 186)	0.006
天门冬氨酸氨基转移酶	118 (54, 303)	58 (34, 106)	61 (35, 139)	<0.001	118 (61, 232)	67 (44, 104)	50 (38, 84)	<0.001

基线数据	MIMIC-IV 队列				eICU-CRD 队列			
	亚组 1（人数=820）	亚组 2（人数=1860）	亚组 3（人数=1318）	*p*	亚组 1（人数=122）	亚组 2（人数=173）	亚组 3（人数=111）	*p*
（U/L）								
总胆红素（mg/dL）	7 (2, 18)	2 (1, 6)	1 (1, 3)	<0.001	8 (2, 13)	3 (1, 6)	2 (1, 4)	<0.001
评分系统								
GCS	14 (12, 15)	15 (14, 15)	15 (14, 15)	<0.001	13 (9, 15)	15 (3, 15)	15 (14, 15)	<0.001
SOFA	13 (10, 15)	8 (6, 10)	5 (4, 8)	<0.001	12 (9, 14)	9 (7, 11)	7 (5, 9)	<0.001
APSIII	85 (72, 101)	56 (46, 67)	41 (33, 51)	<0.001	84 (67, 108)	63 (50, 84)	57 (44, 70)	<0.001
既往病史								
心肌梗死				0.241				0.033
无	749 (91.34%)	1673 (89.95%)	1207 (91.58%)		117 (95.90%)	170 (98.27%)	102 (91.89%)	
有	71 (8.66%)	187 (10.05%)	111 (8.42%)		5 (4.10%)	3 (1.73%)	9 (8.11%)	
充血性心力衰竭				0.110				0.082
无	682 (83.17%)	1483 (79.73%)	1069 (81.11%)		110 (90.16%)	163 (94.22%)	96 (86.49%)	
有	138 (16.83%)	377 (20.27%)	249 (18.89%)		12 (9.84%)	10 (5.78%)	15 (13.51%)	
痴呆				0.549				0.210
无	814 (99.27%)	1839 (98.87%)	1302 (98.79%)		122 (100%)	169 (97.69%)	108 (97.30%)	
有	6 (0.73%)	21 (1.13%)	16 (1.21%)		0 (0%)	4 (2.31%)	3 (2.70%)	
慢性阻塞性肺疾病				0.604				0.062
无	634 (77.32%)	1418 (76.24%)	994 (75.42%)		114 (93.44%)	146 (84.39%)	97 (87.39%)	
有	186 (22.68%)	442 (23.76%)	324 (24.58%)		8 (6.56%)	27 (15.61%)	14 (12.61%)	

基线数据	MIMIC-IV 队列				eICU-CRD 队列			
	亚组 1（人数=820）	亚组 2（人数=1860）	亚组 3（人数=1318）	*p*	亚组 1（人数=122）	亚组 2（人数=173）	亚组 3（人数=111）	*p*
风湿性疾病				0.431				0.236
无	811 (98.90%)	1827 (98.23%)	1297 (98.41%)		121 (99.18%)	166 (95.95%)	108 (97.30%)	
有	9 (1.10%)	33 (1.77%)	21 (1.59%)		1 (0.82%)	7 (4.05%)	3 (2.70%)	
糖尿病				0.001				<0.001
无	570 (69.51%)	1283 (68.98%)	836 (63.43%)		106 (86.89%)	151 (87.28%)	36 (32.43%)	
有	250 (30.49%)	577 (31.02%)	482 (36.57%)		16 (13.11%)	22 (12.72%)	75 (67.57%)	
肾脏疾病				<0.001				<0.001
无	583 (71.10%)	1339 (71.99%)	1053 (79.89%)		95 (77.87%)	157 (90.75%)	79 (71.17%)	
有	237 (28.90%)	521 (28.01%)	265 (20.11%)		27 (22.13%)	16 (9.25%)	32 (28.83%)	
恶性肿瘤				0.003				0.731
无	715 (87.20%)	1655 (88.98%)	1118 (84.83%)		112 (91.80%)	154 (89.02%)	100 (90.09%)	
有	105 (12.80%)	205 (11.02%)	200 (15.17%)		10 (8.20%)	19 (10.98%)	11 (9.91%)	
AIDS				0.075				0.509
无	811 (98.90%)	1833 (98.55%)	1288 (97.72%)		122 (100%)	172 (99.42%)	111 (100%)	
有	9 (1.10%)	27 (1.45%)	30 (2.28%)		0 (0%)	1 (0.58%)	0 (0%)	

3．肝硬化合并脓毒血症患者的亚组分类纵向一致性

本研究第 3 天和第 10 天重复聚类最佳亚组数目均为 3 组（**图 5**）。结果表明，在两个队列中，SSE 曲线均于聚类数 3 处显示转折，提示最佳聚类亚组数均为 3。

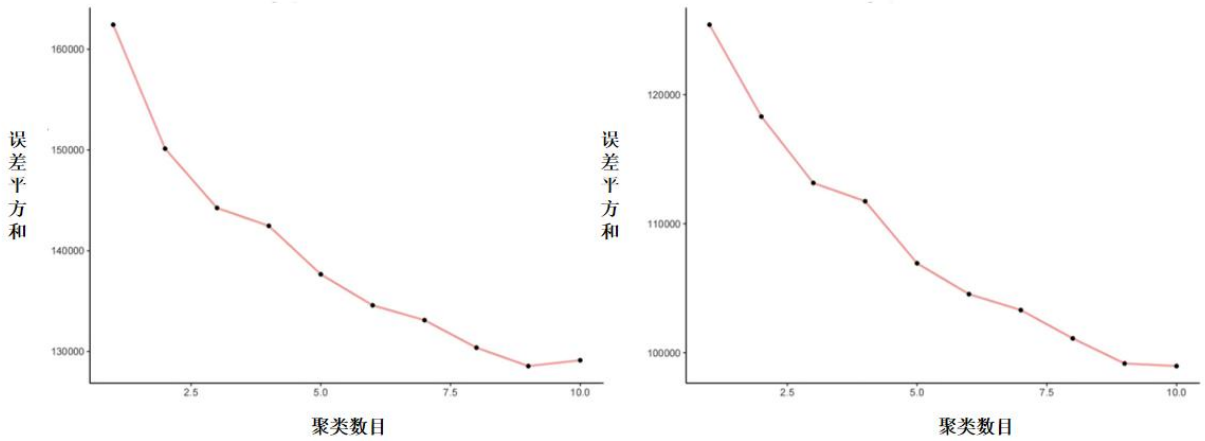

图 5 基于肘方法的第 3 日与第 10 日最佳聚类亚组数目

注：左图为第 3 日示意图，右图为第 10 日示意图

患者第 3 日与第 10 日的临床数据与入院基线数据汇总见**表 5**。与初始入院状态相比，部分基线数据在随时间推移中发生了显著变化。患者群体的 pH 值中位数从入院时的 7.37 小幅上升至第 3 日的 7.38，并在第 10 日保持稳定。血红蛋白和血小板水平则呈现出先下降后回升的趋势：血红蛋白中位数从入院时的 9.35g/dL 降至第 3 日的 9.30g/dL，随后在第 10 日回升至 9.45g/dL；血小板计数中位数从入院时的 110×10⁹/L 降至第 3 日的 93×10⁹/L，而后在第 10 日改善至 112×10⁹/L。然而，肝脏损伤指标（如丙氨酸转氨酶和天门冬氨酸氨基转移酶）的变化趋势则有所不同，表现为先改善后加重的特点。

表 5 第 3 日与第 10 日临床数据与入院基线数据汇总表

变量	入院状态 (人数 = 3998)	第 3 日 (人数 = 3657)	第 10 日 (人数 = 3269)	*p*
人口信息学信息				
性别				0.979
女性	1414 (35.37%)	1301 (35.58%)	1157 (35.39%)	
男性	2584 (64.63%)	2356 (64.42%)	2112 (64.61%)	

变量	入院状态 (人数 = 3998)	第 3 日 (人数 = 3657)	第 10 日 (人数 = 3269)	*p*
年龄	60 (53, 68)	60 (52, 68)	60 (52, 67)	0.627
体重（千克）	81 (69, 97)	82 (70, 98)	81 (69, 97)	0.032
重要生命体征				
心率（次/分钟）	74 (63, 85)	82 (71, 92)	73 (63, 84)	<0.001
收缩压（毫米汞柱）	110 (101, 121)	114 (104, 127)	111 (102, 123)	<0.001
舒张压（毫米汞柱）	60 (54, 67)	62 (55, 70)	61 (55, 68)	<0.001
呼吸频率（次/分钟）	18.60 (16.20, 21.60)	18.50 (16.10, 21.50)	18.20 (16, 21.20)	0.004
体温（摄氏度）	36.80 (36.56, 37.07)	36.82 (36.61, 37.05)	36.83 (36.61, 37.09)	0.002
实验室检查				
pH 值	7.37 (7.32, 7.42)	7.38 (7.34, 7.43)	7.38 (7.32, 7.42)	<0.001
氧分压（毫米汞柱）	98 (63, 162)	103 (69, 155)	98 (63, 169)	0.077
二氧化碳分压（毫米汞柱）	39 (34, 45)	40 (35, 45)	40 (34, 45)	0.007
红细胞比容（%）	28.40 (25.10, 32.50)	28.20 (25.50, 31.30)	28.60 (25.40, 32.80)	0.004
血红蛋白（g/dL）	9.35 (8.20, 10.80)	9.30 (8.30, 10.50)	9.45 (8.30, 10.85)	<0.001
血小板计数（10^9/L）	110 (72, 170)	93 (61, 148)	112 (74, 174)	<0.001
白细胞计数（10^9/L）	9.60 (6.40, 14.20)	7.40 (4.80, 11.30)	9.20 (6.20, 13.40)	<0.001
白蛋白（g/dL）	3 (2.56, 3.45)	3 (2.60, 3.50)	3 (2.60, 3.50)	0.055
阴离子间隙（mmol/L）	15.50 (13, 18.50)	14 (11, 17)	15 (12.50, 17.50)	<0.001
碳酸氢盐（mmol/L）	22 (19, 24.50)	23 (20, 26)	22 (19.50, 25)	<0.001
尿素氮（mg/dL）	28 (16, 46)	25 (14, 44)	26 (16, 42)	<0.001
钙离子（mg/dL）	8.25 (7.75, 8.80)	8.20 (7.80, 8.70)	8.25 (7.75, 8.75)	0.302
氯离子（mmol/L）	102 (98, 107)	103 (99, 108)	103 (98, 107)	<0.001
肌酐（mg/dL）	1.25 (0.85, 2.25)	1.10 (0.70, 1.90)	1.20 (0.80, 2.05)	<0.001
葡萄糖（mg/dL）	128 (106, 166)	115 (97, 142)	129 (107, 167)	<0.001
钠离子（mmol/L）	137 (133.50, 140)	137 (134, 141)	137 (134, 140)	<0.001

变量	入院状态 (人数 = 3998)	第 3 日 (人数 = 3657)	第 10 日 (人数 = 3269)	*p*
钾离子（mmol/L）	4.20 (3.80, 4.75)	3.80 (3.50, 4.20)	4.20 (3.80, 4.70)	<0.001
INR	1.60 (1.35, 2.15)	1.50 (1.25, 1.90)	1.55 (1.30, 2)	<0.001
凝血酶原时间（秒）	18 (15, 23)	16 (14, 21)	17 (14, 21)	<0.001
部分凝血活酶时间（秒）	38 (32, 50)	36 (30, 45)	36 (31, 46)	<0.001
丙氨酸转氨酶（U/L）	34 (20, 70)	31 (18, 66)	32 (19, 67)	0.002
碱性磷酸酶（（U/L）	109 (76, 168)	100 (71, 151)	107 (76, 161)	<0.001
天门冬氨酸氨基转移酶（U/L）	66 (37, 142)	57 (33, 113)	62 (36, 130)	<0.001
总胆红素（mg/dL）	2 (1, 6)	2 (1, 6)	2 (1, 5)	<0.001
评分系统				
GCS	15 (14, 15)	15 (14, 15)	15 (14, 15)	<0.001
SOFA	8 (5, 11)	6 (4, 9)	7 (5, 10)	<0.001
APSIII	55 (42, 72)	46 (35, 60)	52 (40, 67)	<0.001
既往病史				
心肌梗死				0.921
无	3629 (90.77%)	3321 (90.81%)	2960 (90.55%)	
有	369 (9.23%)	336 (9.19%)	309 (9.45%)	
充血性心力衰竭				0.974
无	3234 (80.89%)	2952 (80.72%)	2638 (80.70%)	
有	764 (19.11%)	705 (19.28%)	631 (19.30%)	
痴呆				0.912
无	3955 (98.92%)	3614 (98.82%)	3233 (98.90%)	
有	43 (1.08%)	43 (1.18%)	36 (1.10%)	
慢性阻塞性肺疾病				0.927
无	3046 (76.19%)	2776 (75.91%)	2478 (75.80%)	
有	952 (23.81%)	881 (24.09%)	791 (24.20%)	
风湿性疾病				0.900
无	3935 (98.42%)	3597 (98.36%)	3213 (98.29%)	
有	63 (1.58%)	60 (1.64%)	56 (1.71%)	

变量		入院状态 (人数 = 3998)	第 3 日 (人数 = 3657)	第 10 日 (人数 = 3269)	*p*
糖尿病					0.871
	无	2689 (67.26%)	2444 (66.83%)	2181 (66.72%)	
	有	1309 (33.74%)	1213 (33.17%)	1088 (33.28%)	
肾脏疾病					0.799
	无	2975 (74.41%)	2708 (74.05%)	2410 (73.72%)	
	有	1023 (25.59%)	949 (25.95%)	859 (26.28%)	
恶性肿瘤					0.963
	无	3488 (87.24%)	3195 (87.37%)	2859 (87.46%)	
	有	510 (12.76%)	462 (12.63%)	410 (12.54%)	
AIDS					0.963
	无	3932 (98.35%)	3594 (98.28%)	3215 (98.35%)	
	有	66 (1.65%)	63 (1.72%)	54 (1.65%)	

通过桑基图（**图 6**）展示了亚组随时间变化的动态转化模式。在入院时，绝大多数患者被归类为亚组 2 和亚组 3。随着住院时间的延长，至第 3 日时，大部分死亡病例集中在亚组 1。此外，少量亚组 2 患者转化为亚组 1，而仅有极少数亚组 1 患者降级为亚组 2。同时，亚组 2 与亚组 3 之间存在近似数量的双向转化。至第 7 日时，亚组 2 和亚组 1 对死亡病例的贡献趋于接近。而到第 10 日时，绝大部分初始被归类为亚组 1 的患者仍维持在亚组 1，但大多数亚组 3 患者已升级为亚组 2。最终结局分析显示，亚组 1 患者的死亡比例最高，而亚组 3 患者几乎未出现死亡事件。

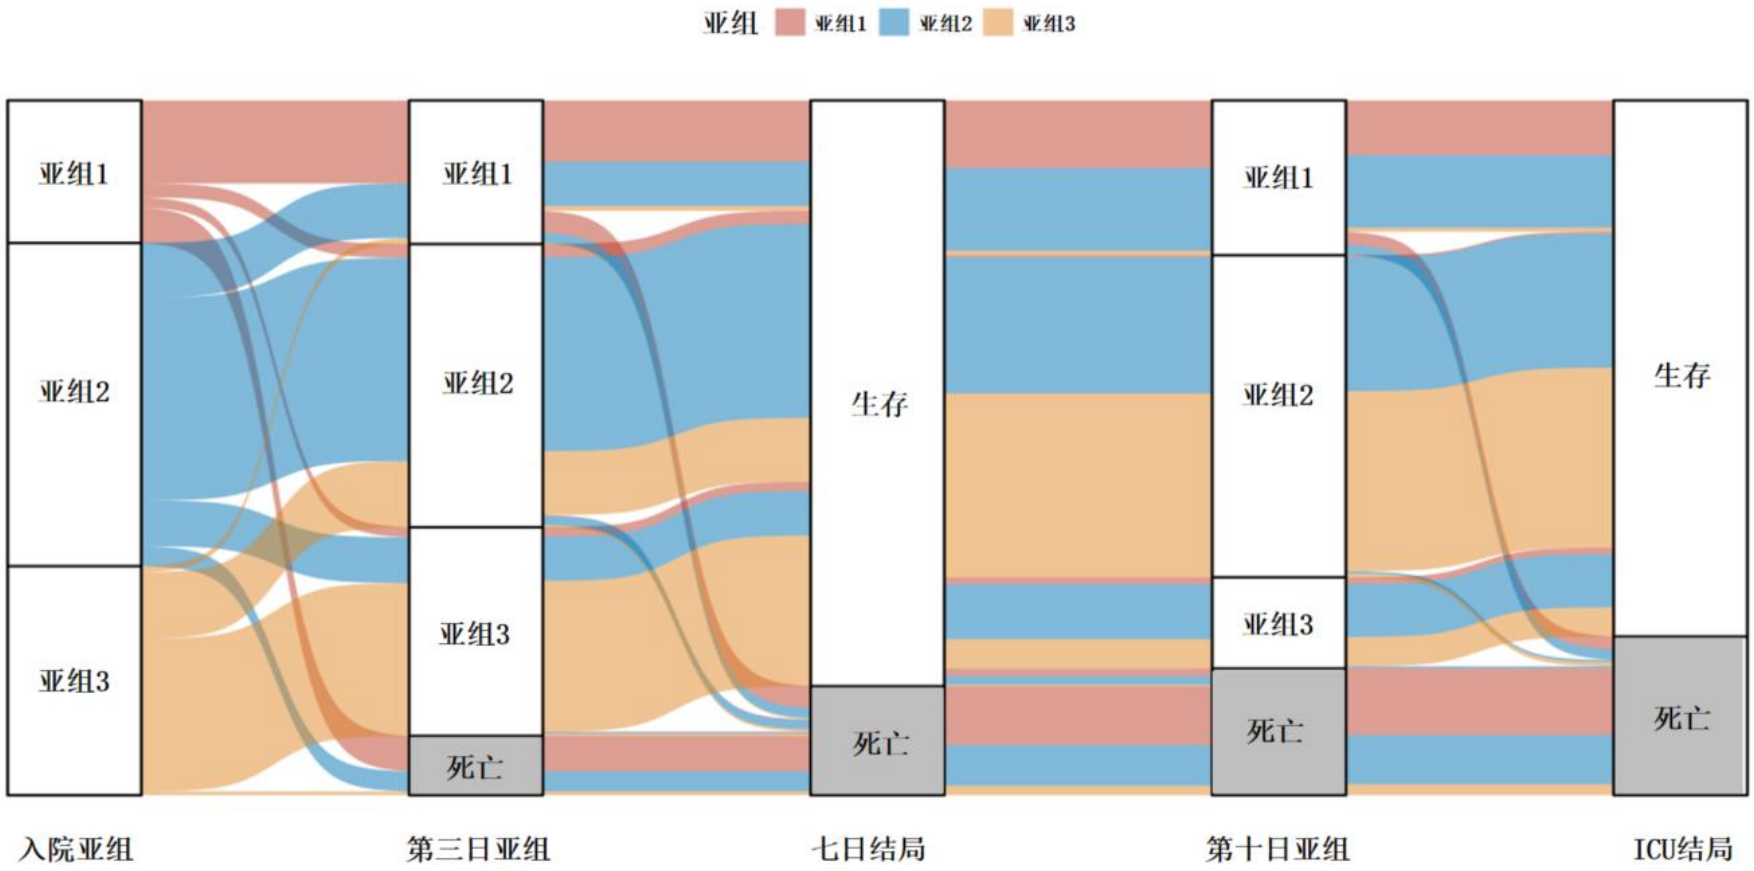

图 6 肝硬化合并脓毒血症患者亚组纵向一致性

4．肝硬化合并脓毒血症患者识别亚组预后分析

根据累计死亡率曲线（**图 7**），各亚组存在显著临床结局差异。亚组 1 人群在两队列中于 7 天，28 天及 ICU 死亡率均展现出最高的累计死亡率，被认为是高危组。亚组 2 和 3 呈现逐渐降低的累计死亡率，被认为是中危组和低危组。

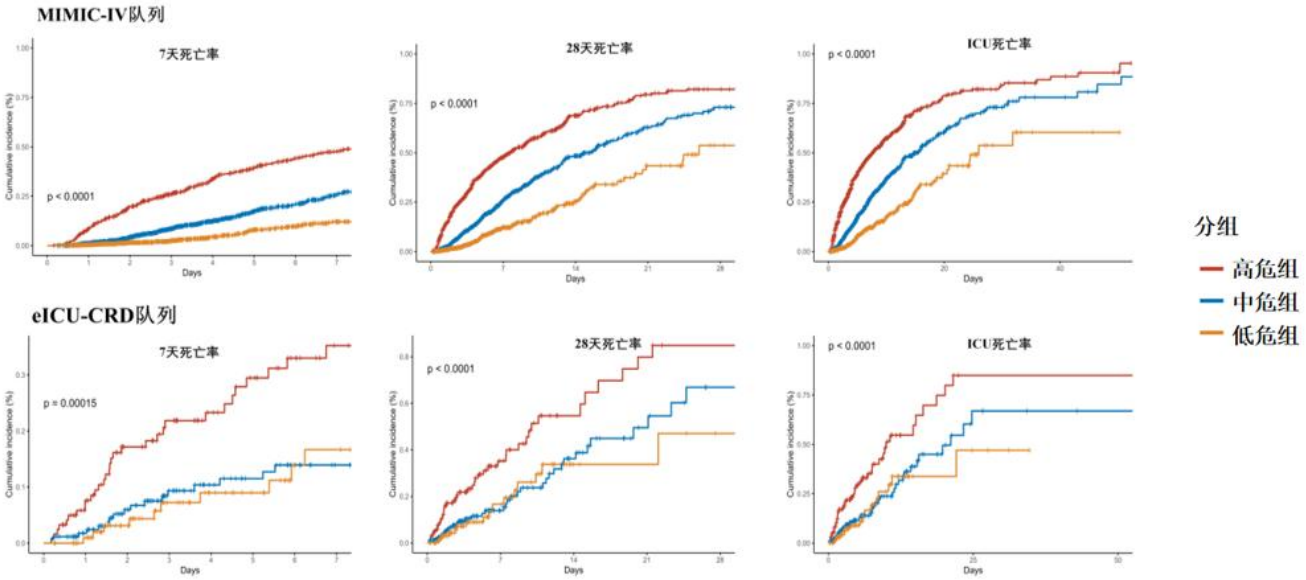

图 7 MIMIC-IV 与 eICU-CRD 队列被识别的亚组累计死亡率曲线

由亚组临床结局汇总表（**表 6**）可知，高危组中患者的 ICU 死亡率最高（MIMIC-IV 队列为 56%，$p < 0.001$；eICU-CRD 队列为 36%，$p < 0.001$）。但对于住院时长，MIMIC-IV 队列中高危组患者住院时间最长（4.2 天，$p < 0.001$），但在 eICU-CRD 队列中，中危组患者住院时间最长（3.6 天，$p < 0.001$）。

表 6 MIMIC-IV 与 eICU-CRD 队列识别亚组临床结局汇总表

队列	亚组 1（高危组）	亚组 2（中危组）	亚组 3（低危组）	*p*
MIMIC-IV 队列				
7 天死亡				<0.001
存活	482 (58.78%)	1626 (87.42%)	1263 (95.83%)	
死亡	338 (41.22%)	234 (12.58%)	55 (4.17%)	
28 天死亡				<0.001
存活	370 (45.12%)	1502 (80.75%)	1229 (93.25%)	
死亡	450 (55.88%)	358 (19.25%)	89 (6.75%)	
ICU 死亡				<0.001
存活	363 (44.27%)	1494 (80.32%)	1228 (93.17%)	
死亡	457 (55.73%)	366 (19.68%)	90 (6.83%)	
住院时长 (天)	4.20 (2, 9)	2.90 (1.80, 5.90)	2.40 (1.40, 4.80)	<0.001
eICU-CRD 队列				
7 天死亡				<0.001
存活	91 (74.59%)	156 (90.17%)	101 (90.99%)	
死亡	31 (25.41%)	17 (9.83%)	10 (9.01%)	
28 天死亡				<0.001
存活	78 (63.93%)	137 (79.20%)	95 (85.59%)	
死亡	44 (36.07%)	36 (20.80%)	16 (14.41%)	
ICU 死亡				<0.001
存活	78 (63.93%)	137 (79.20%)	95 (85.59%)	
死亡	44 (36.07%)	36 (20.81%)	16 (14.41%)	
住院时长 (天)	3.20 (1.60, 6.60)	3.60 (1.80, 9.20)	3.50 (1.70, 7.40)	0.225

两队列中识别的亚组与临床结局的多因素 Cox 回归结果分别汇总于**表 7** 和**表 8**。与高危组相比，低危组具有最低的 ICU 死亡风险（MIMIC-IV 队列：HR = 0.21，95%置信区间 0.16 - 0.25，$p < 0.001$；eICU-CRD 队列 HR = 0.36，95%置信区间 0.20 - 0.64，$p < 0.001$）。即使在调整既往病史、实验室检查指标后也如此（在 MIMIC-IV 队列中

HR = 0.22，95%置信区间 0.17 - 0.28，$p < 0.001$；在 eICU-CRD 队列中 HR = 0.37，95%置信区间 0.20 - 0.69，$p < 0.001$）。

表格 7 MIMIC-IV 队列中识别亚组和临床结局多因素 Cox 回归结果

	模型 1*		模型 2**		模型 3***	
	HR (95% CI)	***p***	**HR (95% CI)**	***p***	**HR (95% CI)**	***p***
			28 天 ICU 死亡			
亚组 1（高危组）			参照			
亚组 2（中危组）	0.47 (0.41-0.54)	<0.001	0.44 (0.38-0.51)	<0.001	0.50 (0.42-0.58)	<0.001
亚组 3（低危组）	0.19 (0.16-0.25)	<0.001	0.18 (0.14-0.23)	<0.001	0.22 (0.17-0.28)	<0.001
			7 天 ICU 死亡			
亚组 1（高危组）			参照			
亚组 2（中危组）	0.37 (0.32-0.44)	<0.001	0.35 (0.30-0.42)	<0.001	0.39 (0.33-0.47)	<0.001
亚组 3（低危组）	0.14 (0.11-0.19)	<0.001	0.13 (0.10-0.17)	<0.001	0.16 (0.12-0.21)	<0.001
			ICU 死亡			
亚组 1（高危组）			参照			
亚组 2（中危组）	0.47 (0.81-0.54)	<0.001	0.44 (0.38-0.51)	<0.001	0.49 (0.42-0.57)	<0.001
亚组 3（低危组）	0.21 (0.16-0.25)	<0.001	0.18 (0.14-0.23)	<0.001	0.22 (0.17-0.28)	<0.001

注：*：调整年龄与性别；**：在在模型 1 的基础上进一步纳入既往病史（包括糖尿病、高血压等），***：在模型 2 的基础上再次调整实验室检查指标（包含肝功能指标、炎症标志物等）。

表 8 eICU-CRD 队列中识别亚组和临床结局多因素 Cox 回归结果

	模型 1*		模型 2**		模型 3***	
	HR (95% CI)	***p***	**HR (95% CI)**	***p***	**HR (95% CI)**	***p***
28 天 ICU 死亡						
亚组 1（高危组）	参照					
亚组 2（中危组）	0.43 (0.28-0.67)	<0.001	0.38 (0.23-0.64)	<0.001	0.43 (0.25-0.73)	0.002
亚组 3（低危组）	0.26 (0.20-0.64)	<0.001	0.33 (0.17-0.63)	<0.001	0.37 (0.20-0,69)	0.002
7 天 ICU 死亡						
亚组 1（高危组）	参照					
亚组 2（中危组）	0.35 (0.20-0.64)	<0.001	0.38 (0.20-0.76)	0.006	0.36 (0.18-0.73)	0.005
亚组 3（低危组）	0.34 (0.17-0.69)	0.002	0.25 (0.11-0.56)	<0.001	0.31 (0.14-0.69)	0.004
ICU 死亡						
亚组 1（高危组）	参照					
亚组 2（中危组）	0.43 (0.27-0.67)	<0.001	0.38 (0.23-0.64)	<0.001	0.43 (0.26-0.73)	<0.001
亚组 3（低危组）	0.36 (0.20-0.64)	<0.001	0.33 (0.17-0.63)	<0.001	0.37 (0.20-0.69)	<0.001

注：*：调整年龄与性别；****：在在模型 1 的基础上进一步纳入既往病史（包括糖尿病、高血压等），*****：在模型 2 的基础上再次调整实验室检查指标（包含肝功能指标、炎症标志物等）。

5. 白蛋白早期输注策略对肝硬化合并脓毒血症亚组患者预后分析

MIMIC-IV 队列患者早期白蛋白输注情况汇总于**表 9**。数据显示，在队列中每日仅有 10%-20%的患者接受白蛋白输注，且使用比例随时间逐渐下降。值得注意的是，在存活组与死亡组的对比中，死亡患者中白蛋白的使用比例显著更高。

表 9　MIMIC-IV 队列患者早期白蛋白输注情况汇总表

输注白蛋白	总体队列 (人数 = 3998)	存活 （人数 = 3085）	死亡 （人数 = 913）	*p*
第一日				<0.001
未输注	3248 (81.24%)	2566 (83.18%)	682 (74.70%)	
输注	750 (18.76%)	519 (16.82%)	231(25.30%)	
第二日				0.001
未输注	3437 (85.97%)	2682 (86.94%)	755 (82.69%)	
输注	561 (14.03%)	403 (13.06%)	158 (17.31%)	
第三日				<0.001
未输注	3635 (90.92%)	2838 (91.99%)	797 (87.29%)	
输注	363 (9.08%)	247 (8.01%)	116 (12.71%)	

早期白蛋白输注策略对亚组患者预后影响的多因素 Cox 回归分析结果可视化于**图 8**。从图中可以看出，对于总体人群而言，第一日白蛋白输注表现为显著的危险因素（HR = 1.49，95%置信区间 1.28 - 1.73，$p < 0.001$）。然而，在高危组中，除第一日白蛋白输注为危险因素外（HR = 1.28，95%置信区间 1.06 - 1.56，$p = 0.01$），第二日（HR = 0.75，95%置信区间 0.59 – 0.95，$p = 0.02$）和第三日（HR = 0.64，95%置信区间 0.48 – 0.84，$p < 0.001$）的白蛋白输注则表现出保护作用。相比之下，中危组和低危组未观察到白蛋白输注对预后的显著影响。

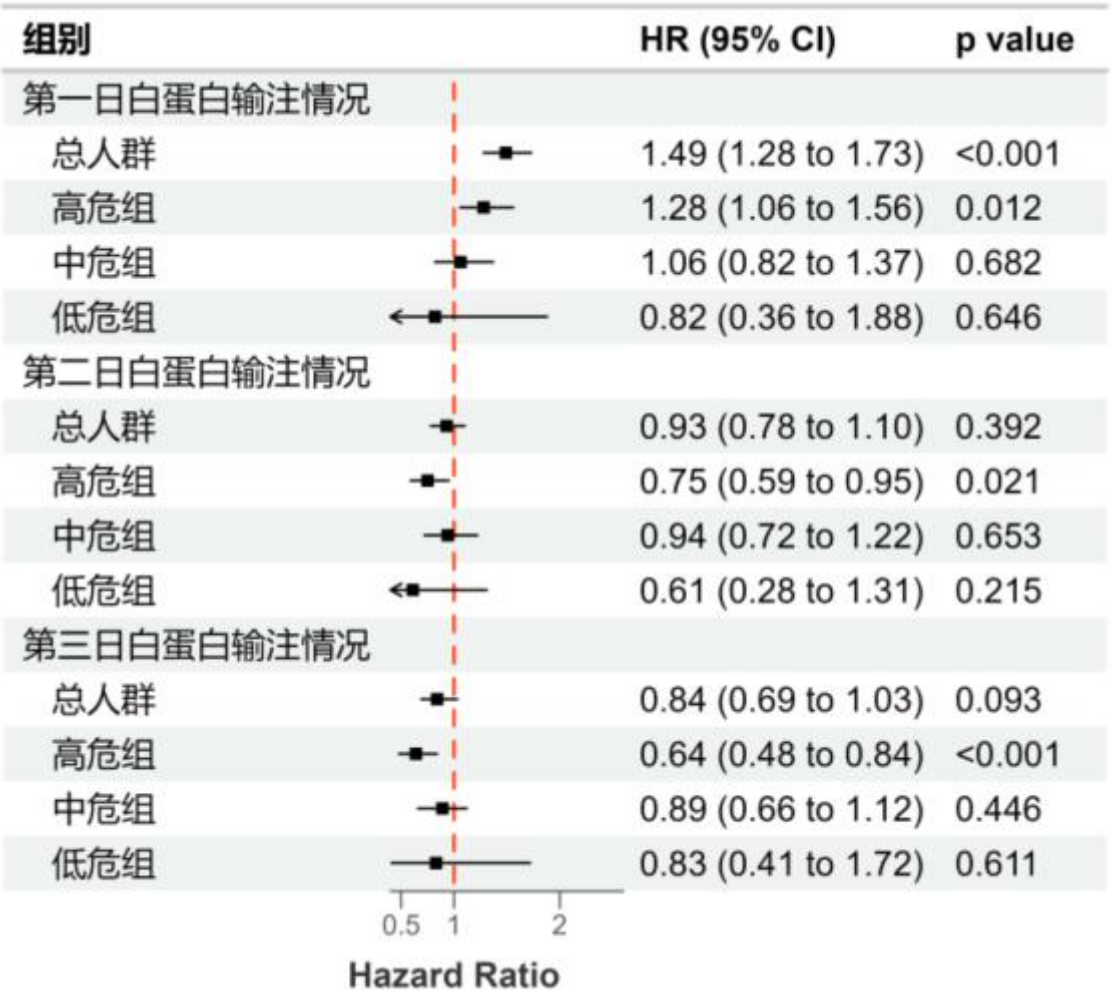

图 8 早期白蛋白输注策略对亚组患者预后影响的多因素 Cox 回归

经倾向性评分匹配后，以第一日、第二日和第三日白蛋白输注与否为干预措施的各协变量均匹配皆均衡，即标准均差值均小于 0.1（**图 8**）。

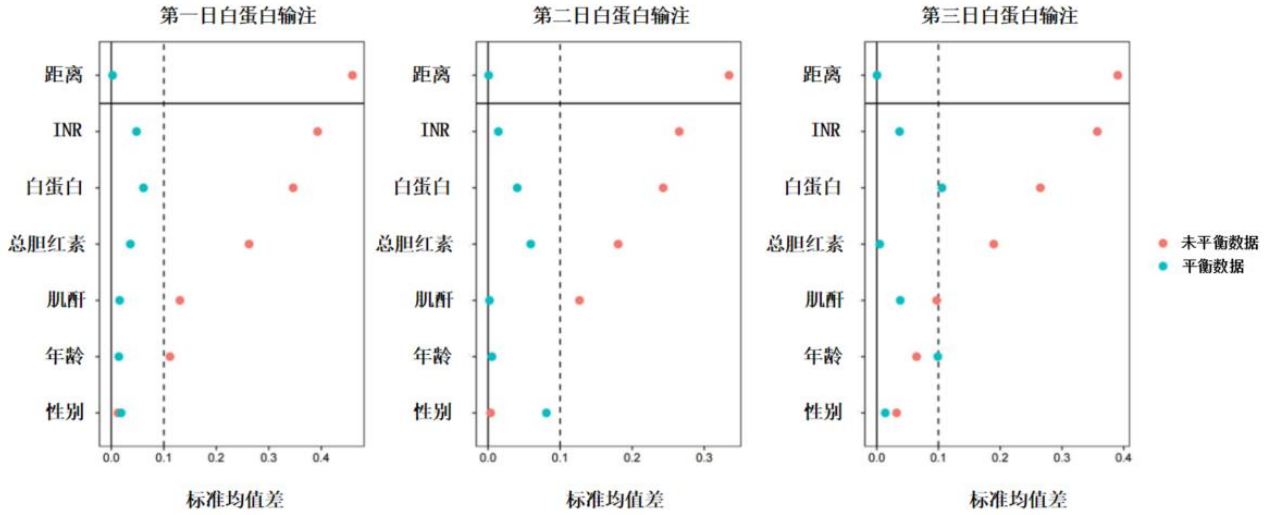

图 8 倾向性评分计算变量匹配前后 SMD 差异

匹配后亚组患者早期白蛋白输注与预后的 Cox 回归分析结果可视化于**图 9**。结果显示，经匹配后，仅在高危亚组中观察到第二日（HR = 0.69，95%置信区间 0.51 - 0.93，p = 0.02）和第三日（HR = 0.59，95%置信区间 0.40 - 0.88，p = 0.008）白蛋白输注对预后具有显著的保护作用，第一日高危组患者白蛋白输注则无明显统计学意义（HR = 1.02，95%置信区间 0.79 - 1.29，p = 0.89）。对于其余中危与低危组患者，早期白蛋白输注对临床结局均未呈现统计学意义。

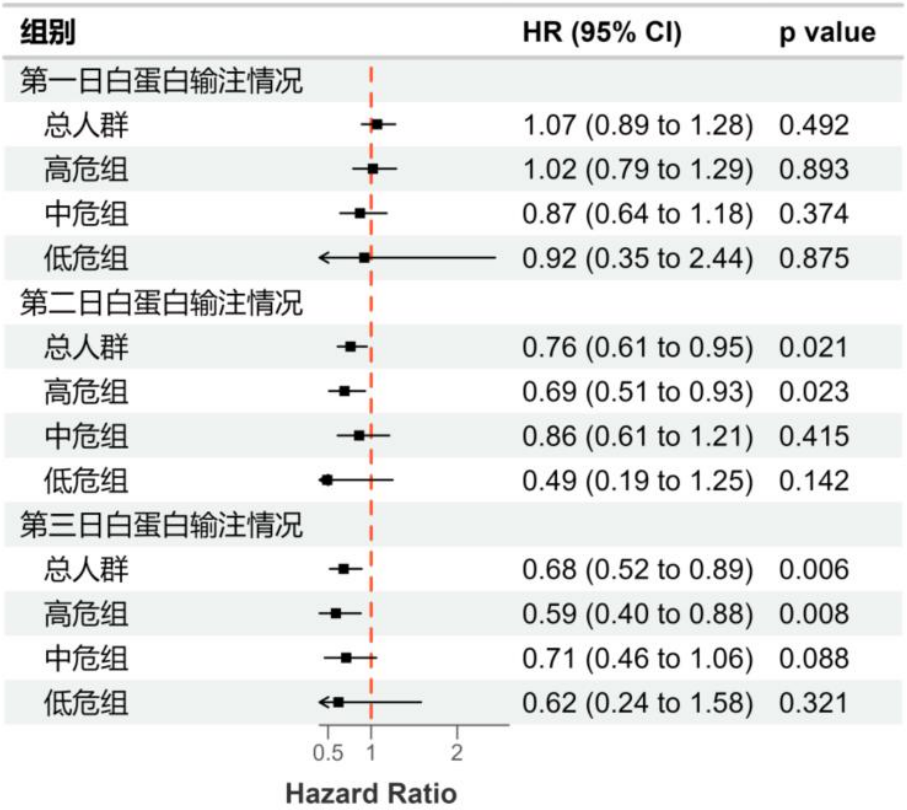

图 9 匹配后早期白蛋白输注策略对亚组患者预后影响的多因素 Cox 回归

6．基于机器学习算法的早期亚组识别与预后模型建立验证与部署

基于信息熵筛选（**图 10**），共有 10 个变量信息熵分数大于 0.1，被初步纳入，分别是红细胞比容，INR，凝血酶原时间，血红蛋白，阴离子间隙，肌酐，碳酸氢盐，部分凝血活酶时间，总胆红素和尿素氮。其中红细胞比容被认为具有最高的信息熵分数。

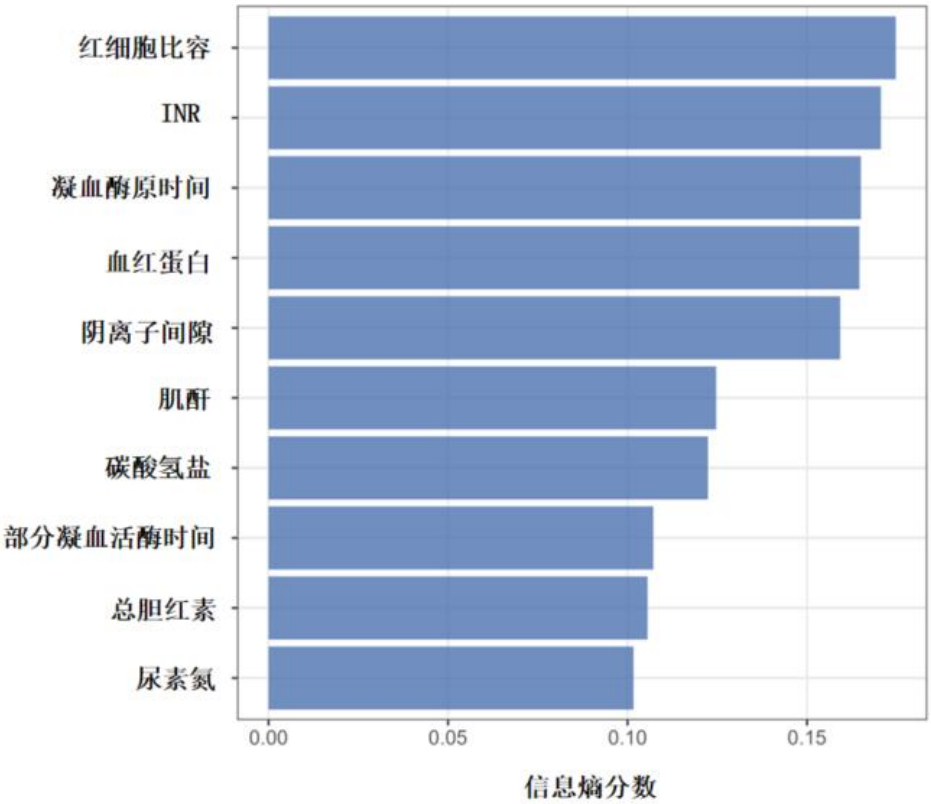

图 10 基于信息熵筛选初步筛选结果

后经相关性分析（**图 11**），初筛变量中部分变量存在高度相关性：红细胞比容与血红蛋白的相关性为 0.96，INR 与凝血酶原时间的相关性为 0.94。为避免冗余变量对模型性能和可解释性的影响，根据信息熵分数排序，最终剔除了凝血酶原时间和血红蛋白两个变量。

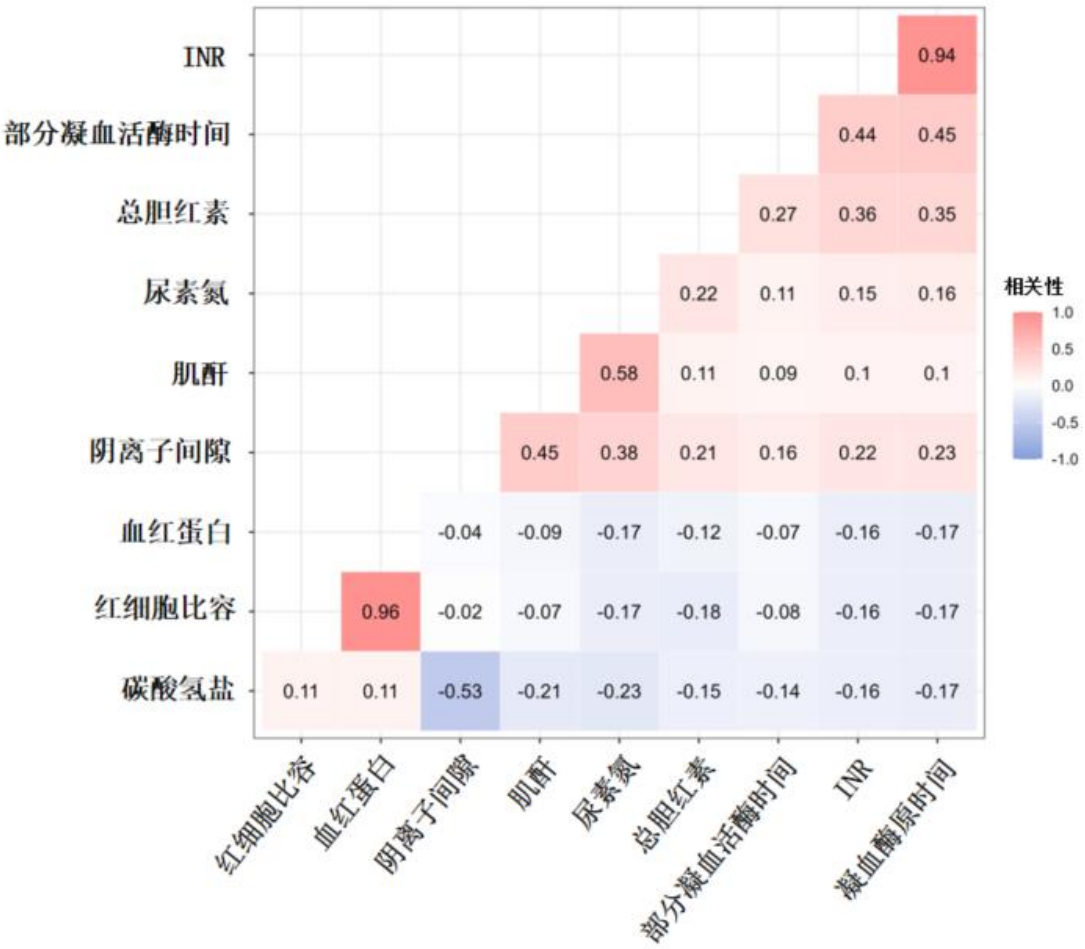

图 11 初步筛选变量相关性分析

在利用 RFE 算法筛选最佳变量组合时（**图 12**），结果表明，当纳入全部 8 项初筛变量时，模型能够达到最佳的准确性和 Kappa 系数。但由图可明确，当变量数量达到 5 个后，模型性能的提升趋于平缓，从 5 个变量增加至 8 个变量时性能改善并不显著。此外，为了提高模型在临床实践中的便捷性和易用性，最终确定了 5 个关键预测变量：红细胞比容、INR、阴离子间隙、肌酐和总胆红素。

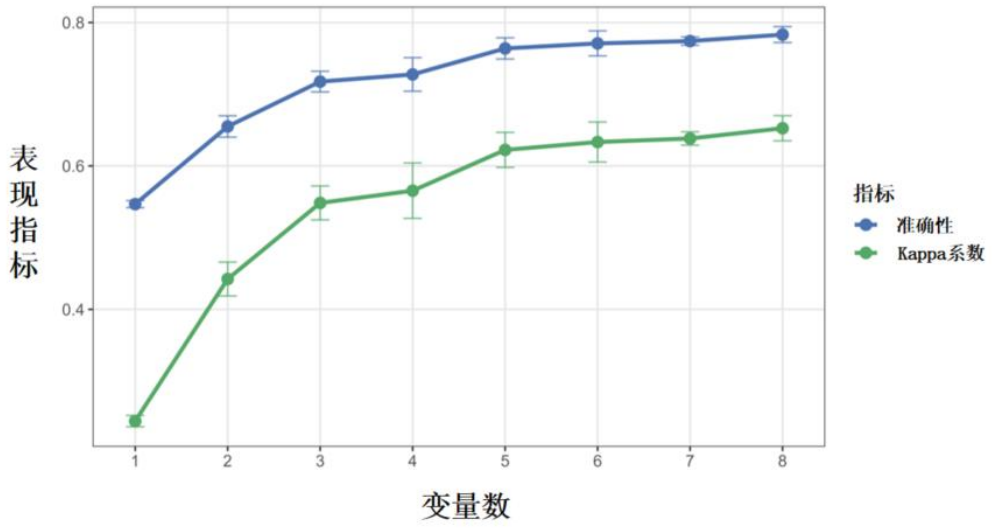

图 12 基于 RFE 算法的最佳预测变量组合

注：横坐标为纳入变量数，纵坐标为模型表现性能

经过 10 折交叉验证评估，随机森林算法表现出综合最优性能（**图 13**），其平均宏曲线下面积为 0.93, 95%置信区间（0.86 – 0.99）;平均宏布里尔评分为 0.32, 95%置信区间（0.12 – 0.36），平均准确性为 0.89, 95%置信区间（0.86 – 0.95），高于其余算法平均表现，表明随机森林模型对该数据集任务的适应性。

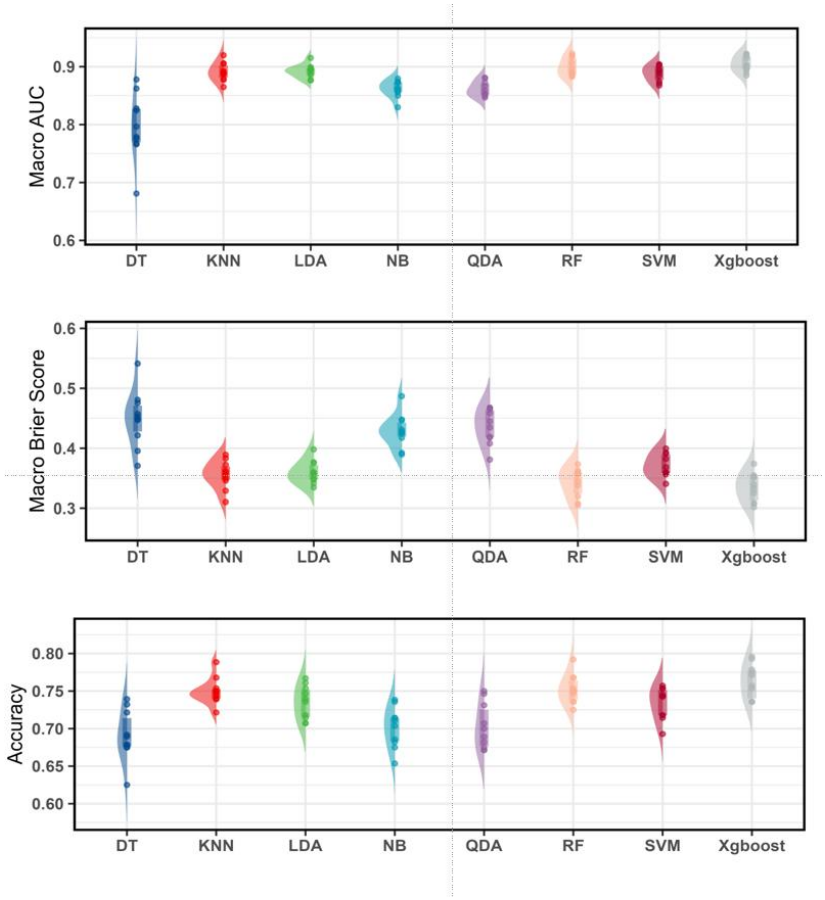

图 13 经 10 折交叉验证算法平均表现

注：DT：决策树，KNN：K 近邻，LDA：线性判别分析，NB：朴素贝叶斯，QDA：二次判别分析，RF：随机森林，SVM：支持向量机，Xgboost：极限梯度提升

基于最佳超参数，建立了亚组早期识别模型，其在各数据集上的表现详见**表 9**。亚组早期识别模型在训练集上表现优异，其准确性、宏曲线下面积和宏布里尔评分分别为 0.95、0.99 和 0.12。然而，在内部验证集（准确性 0.76，宏曲线下面积 0.89）和外部验证集（准确性 0.69，宏曲线下面积 0.86）上的性能有所下降。混淆矩阵显示模型对高危组分类效果较好，但低危组的误分类率较高。

表 9 基于随机森林算法的亚组早期识别模型于各数据集表现

数据集	准确性	宏曲线下面积	宏布里尔评分	混淆矩阵			
训练集	0.95	0.99	0.12	预测 真实	高危组	中危组	低危组
				高危组	516	9	5
				中危组	36	1276	54
				低危组	10	28	865
内部验证集	0.76	0.89	0.34	预测 真实	高危组	中危组	低危组
				高危组	176	28	8
				中危组	74	446	98
				低危组	8	73	288
外部验证集	0.69	0.86	0.43	预测 真实	高危组	中危组	低危组
				高危组	87	13	8
				中危组	30	148	62
				低危组	5	12	41

在真实世界测试集-苏州队列中，利用亚组早期预测模型预测患者亚组，其累计死亡率曲线可视化于**图 14**。高危组累计死亡率显著高于中危组与低危组（$p = 0.042$）。

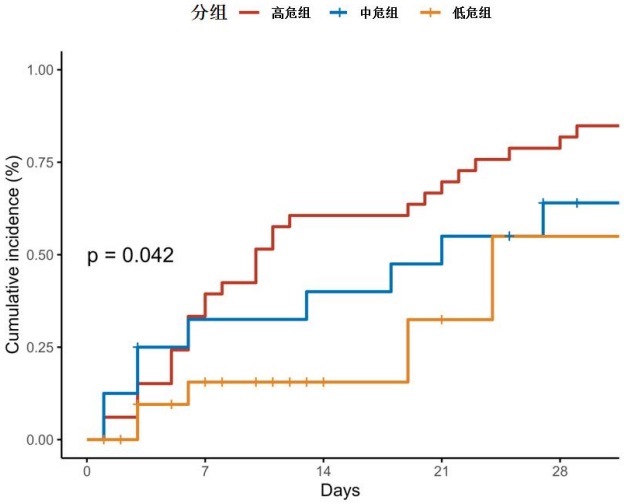

图 14 基于苏州队列亚族早期预测模型预测亚族的累计死亡曲线

亚组早期预测模型对苏州队列中各亚组预测结果的基线数据比较汇总于**表 10**。在苏州队列中，共有 16 名患者被识别为高危组，24 名为中危组，33 名为低危组。高

危组患者的死亡率显著高于中危组和低危组（63%，$p < 0.001$），显示出该亚组的高风险特征。从基线数据来看，高危组患者表现出显著的内环境紊乱和多器官功能损伤。高危组患者更倾向于酸中毒，其 pH 值中位数为 7.31，低于中危组和低危组。此外，高危组患者的肝功能指标显著升高，丙氨酸转氨酶中位数为 40 U/L，天门冬氨酸氨基转移酶中位数为 90 U/L，提示更严重的肝脏损伤。同时，高危组患者的肾功能指标也显著异常，肌酐中位数为 1.72 mg/dL，进一步反映了肾脏损伤的严重程度。

表 10 基于早期亚组预测模型预测的苏州队列亚组重要基线变量比较

基线变量	高危组（人数=16）	中危组（人数=24）	低危组（人数=33）	*P*
人口信息学信息				
性别				0.599
女性	7 (43.75%)	7 (29.17%)	13 (39.39%)	
男性	9 (56.25%)	17 (70.83%)	20 (60.61%)	
年龄	58 (49, 75)	65 (60, 72)	68 (53, 76)	0.723
体重（千克）	65 (57, 70)	73 (65, 77)	67 (59, 78)	0.140
重要生命体征				
心率（次/分钟）	95 (84, 105)	82 (77, 105)	78 (74, 95)	0.214
收缩压（毫米汞柱）	92 (81, 100)	98 (89, 105)	100 (93, 116)	0.048
舒张压（毫米汞柱）	55 (48, 65)	62 (55, 65)	66 (60, 71)	0.006
呼吸频率（次/分钟）	18 (15, 20)	18 (16, 22)	18 (15, 20)	0.463
体温（摄氏度）	36.80 (36.28, 37.13)	36.90 (36.50, 37.23)	36.80 (36.50, 37.30)	0.523
实验室检查				
pH 值	7.31 (7.19, 7.42)	7.42 (7.21, 7.44)	7.42 (7.35, 7.43)	0.236
氧分压（毫米汞柱）	104 (76, 145)	94 (68, 116)	94 (74, 118)	0.719
白细胞计数（10^9/L）	10 (7, 18)	12 (5, 16)	9 (6, 14)	0.623
血红蛋白（g/dL）	88 (71, 110)	101 (69, 114)	99 (76, 122)	0.645
红细胞比容（%）	24 (17, 33)	32 (21, 37)	30 (23, 36)	0.393
血小板计数（10^9/L）	83 (56, 138)	88 (43, 140)	95 (65, 126)	0.723

基线变量	高危组（人数=16）	中危组（人数=24）	低危组（人数=33）	*P*
葡萄糖（mg/dL）	136.8 (115.2, 178.2)	113.4 (99, 156.6)	120.6 (90, 144)	0.330
氯离子（mmol/L）	103 (98, 107)	103 (100, 108)	106 (100, 110)	0.725
钠离子（mmol/L）	139 (134, 143)	137 (133, 140)	136 (135, 141)	0.683
钙离子（mg/dL）	7.04 (4.68, 8.44)	8.20 (7.84, 9.04)	7.76 (7.40, 8.24)	0.076
阴离子间隙（mmol/L）	16 (10, 28)	15 (13, 20)	11 (10, 14)	0.034
碳酸氢盐（mmol/L）	22 (17, 26)	19 (17, 24)	21 (18, 24)	0.923
丙氨酸转氨酶（U/L）	40 (25, 113)	30 (16, 107)	29 (14, 64)	0.574
天门冬氨酸氨基转移酶（U/L）	90 (47, 140)	56 (38, 86)	36 (21, 86)	0.057
总胆红素（mg/dL）	2.22 (0.99, 5.03)	2.04 (1.64, 4.79)	1.87 (1.40, 3.39)	0.294
白蛋白（g/dL）	2.87 (2.64, 3.01)	2.91 (2.66, 3.29)	2.94 (2.44, 3.31)	0.813
肌酐（mg/dL）	1.72 (1.04, 2.18)	1.40 (0.71, 2.10)	0.80 (0.63, 1.38)	0.234
尿素氮（mg/dL）	15 (9, 17)	11 (8, 17)	10 (7, 21)	0.673
碱性磷酸酶（U/L）	85 (49, 136)	102 (73, 145)	95 (80, 125)	0.682
INR	1.66 (1.53, 2.33)	1.53 (1.27, 2.06)	1.33 (1.19, 1.55)	0.008
凝血酶原时间（秒）	20 (18, 26)	17 (16, 23)	16 (15, 18)	0.007
部分凝血活酶时间（秒）	48 (41, 62)	41 (38, 52)	36 (31, 40)	0.003
住院时间（天）	16 (3, 28)	7 (3, 12)	11 (6, 22)	0.120
结局				<0.001
存活	6 (37.50%)	17 (70.83%)	0 (0%)	
死亡	10 (62.50%)	7 (29.17%)	33 (100%)	

为进一步增强模型的可解释性，基于 SHAP 算法对模型进行全局解释（**图 15**）。结果表明，阴离子间隙对预测高危组患者的贡献最为显著，且随着阴离子间隙数值的增加，模型更倾向于将患者判定为高危组。对于中危组和低危组患者，红细胞比容是最重要变量，但其数值大小对模型预测结果的影响方向相反：当红细胞比容数值较大时，患者更可能被预测为低危组；而当红细胞比容数值较小时，则更可能被预测为中危组。

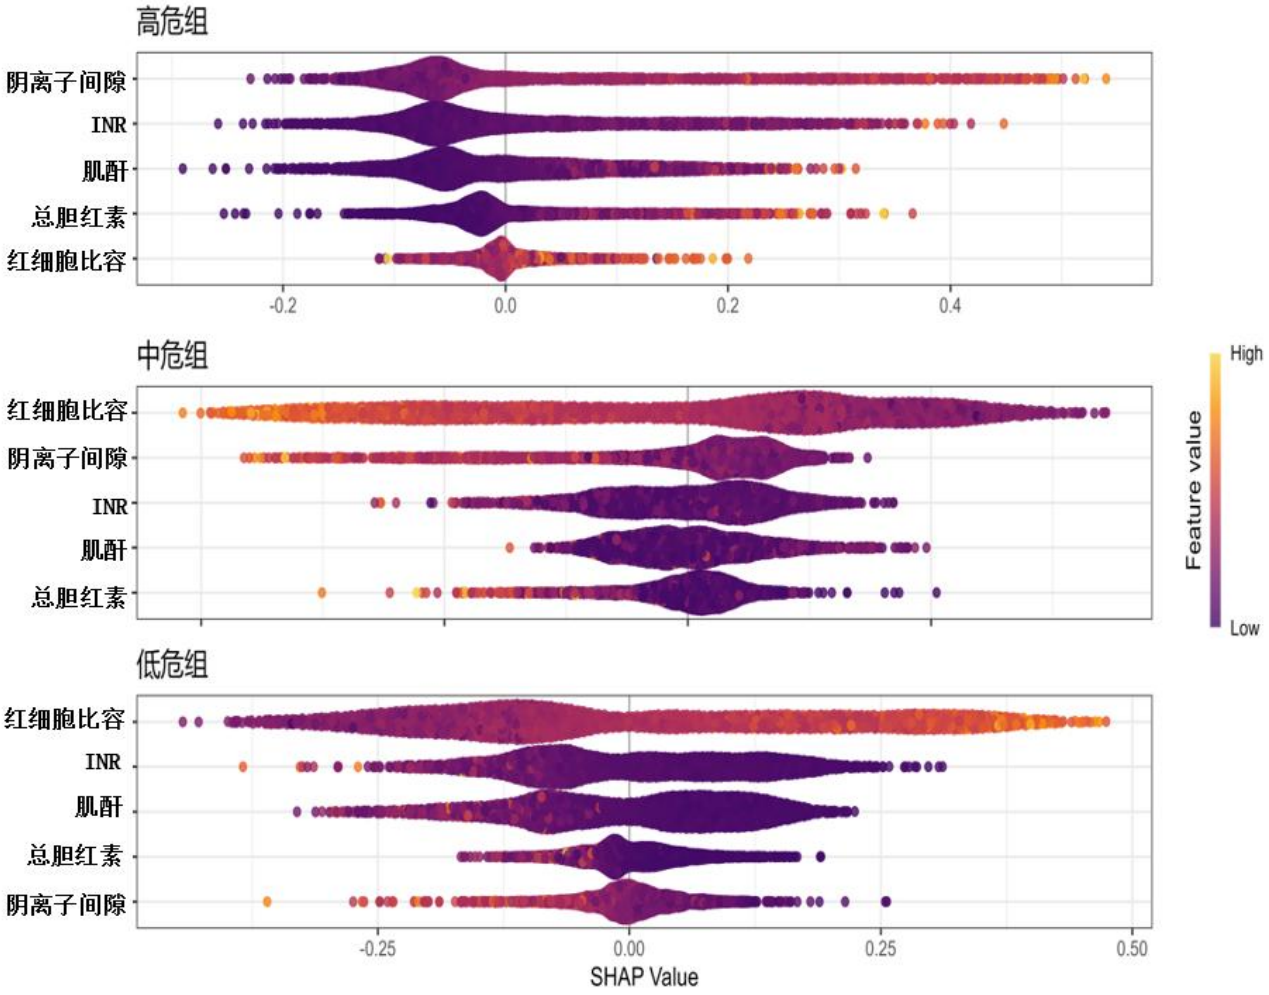

图 15 基于 SHAP 算法的随机森林模型全局解释

此外，基于 Breakdown 算法实现了个体层面的预测解释（**图 16**）。该图可视化展示了从高危、中危和低危组中随机抽取的三名患者个体预测结局的依据。患者的分组概率被分解为各变量的概率贡献，直观呈现了每个变量对个体预测结果的影响。例如，对于图中高危患者（实际属于高危亚组，模型预测其为高危亚组的概率为 0.609），Breakdown 算法将其预测概率分解如下：国际标准化比值（INR）为 2.8 贡献了 0.2 的高危组概率，肌酐为 3.2 贡献了 0.185 的概率，阴离子间隙为 18 贡献了 0.131 的概率。然而，相对较低的红细胞比容降低了 0.014 的概率，而总胆红素为 1.4 则进一步降低了 0.029 的概率。这种分解不仅清晰地揭示了各个变量对预测结果的正向或负向贡献，还为临床医生提供了直观的决策支持。

图 16 基于 Breakdown 算法的患者个体预测解释

注：高危组患预测值患者分组识别亚组为高危组，基于早期预测模型亦预测为高危组。中危组与低危组同理。

最后，**图 17** 展示了各变量对预测结局的依赖关系，揭示了模型如何根据变量数值的变化影响预测结果。对于阴离子间隙，当其数值较低时，对中危组和低危组的预测结果影响较大；但随着数值的增加，其对高危组患者预后的影响迅速增强，而对中危组和低危组的影响则逐渐减弱。红细胞比容在数值较低时对中危组患者的预测结果影响显著，倾向于将患者分类为中危组；然而，随着数值的升高，患者更可能被预测为低危组。INR 则表现出明确的趋势，随着其数值的升高，患者被分类为高危组的概率显著增加，表明该变量在区分高危患者方面具有重要作用。肌酐和总胆红素呈现出类似的趋势，即对中危组患者的预测结果影响较大，但受数值变化的影响相对较小。这些分析不仅揭示了各变量对不同风险分组的动态影响，还为进一步优化模型和指导临床决策提供了重要依据。

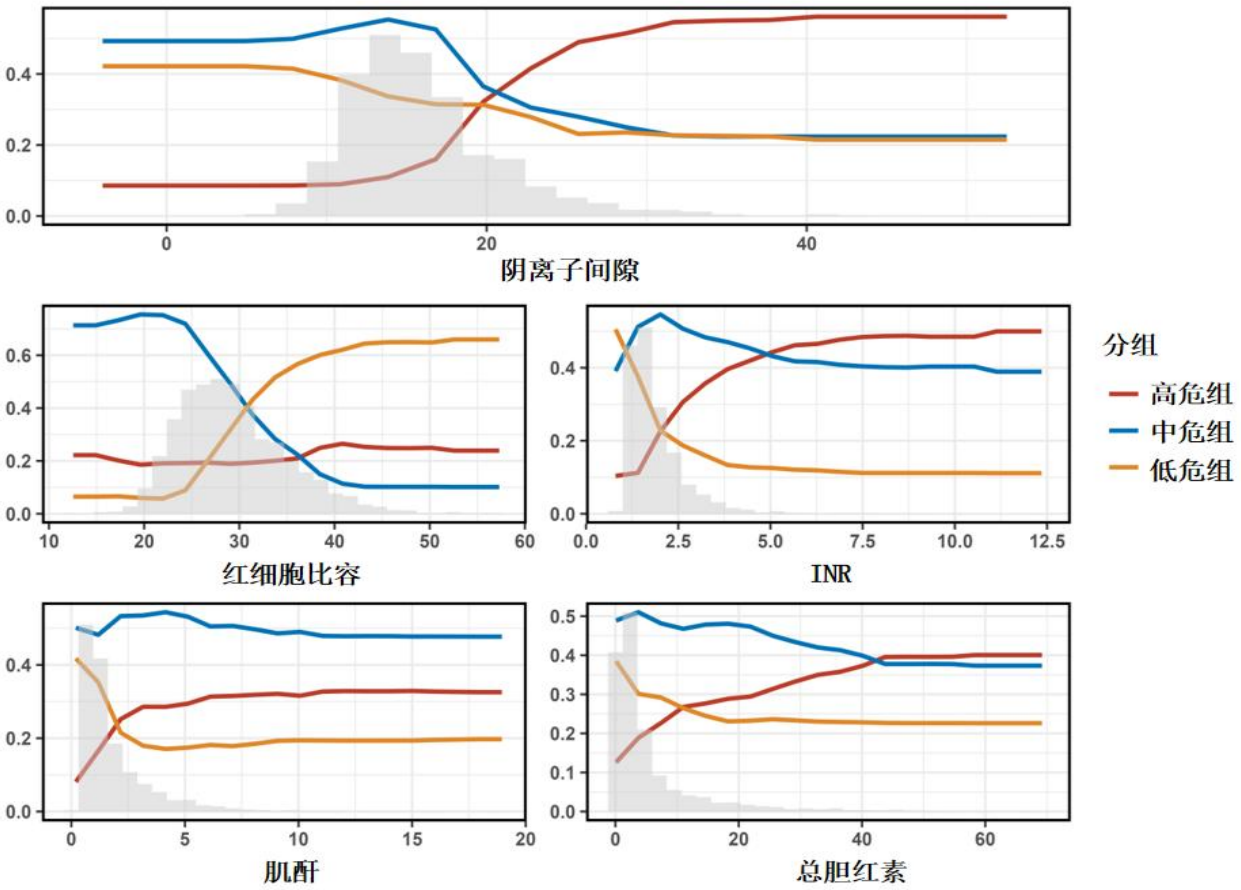

图 17 各变量基于 PDP 算法的结局影响

模型最终在线部署于网页（http://39.101.122.171:3838/App3/），其界面直观且便于使用，并提供了个体决策依据（**图 18 与图 19**）。

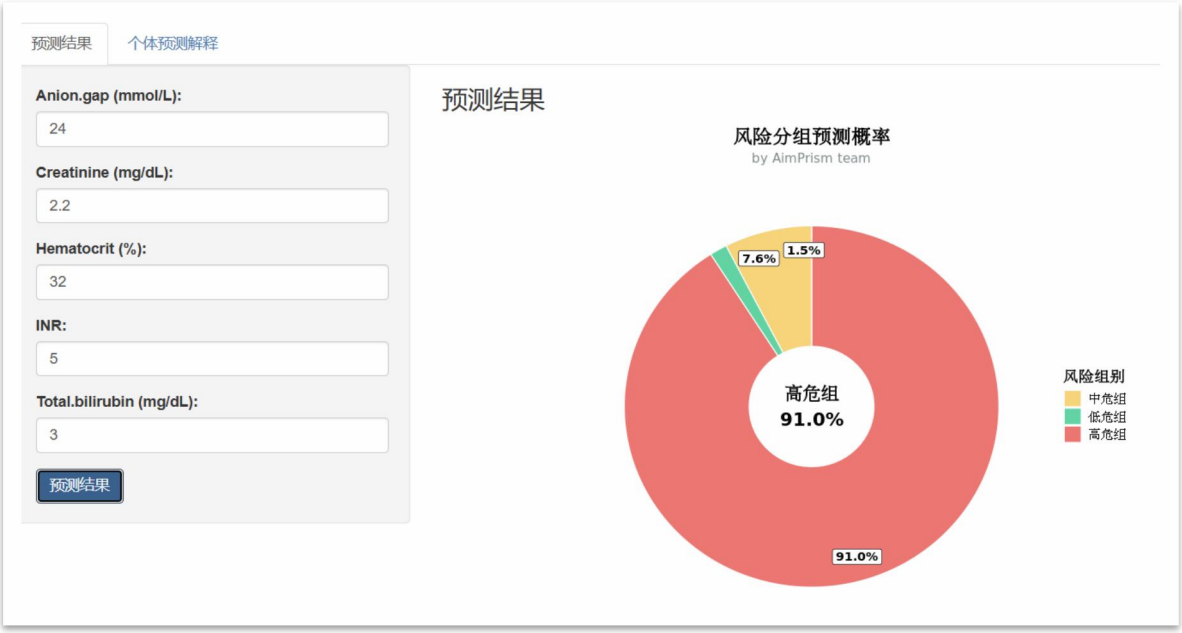

图 18 在线部署模型预测结果示意图

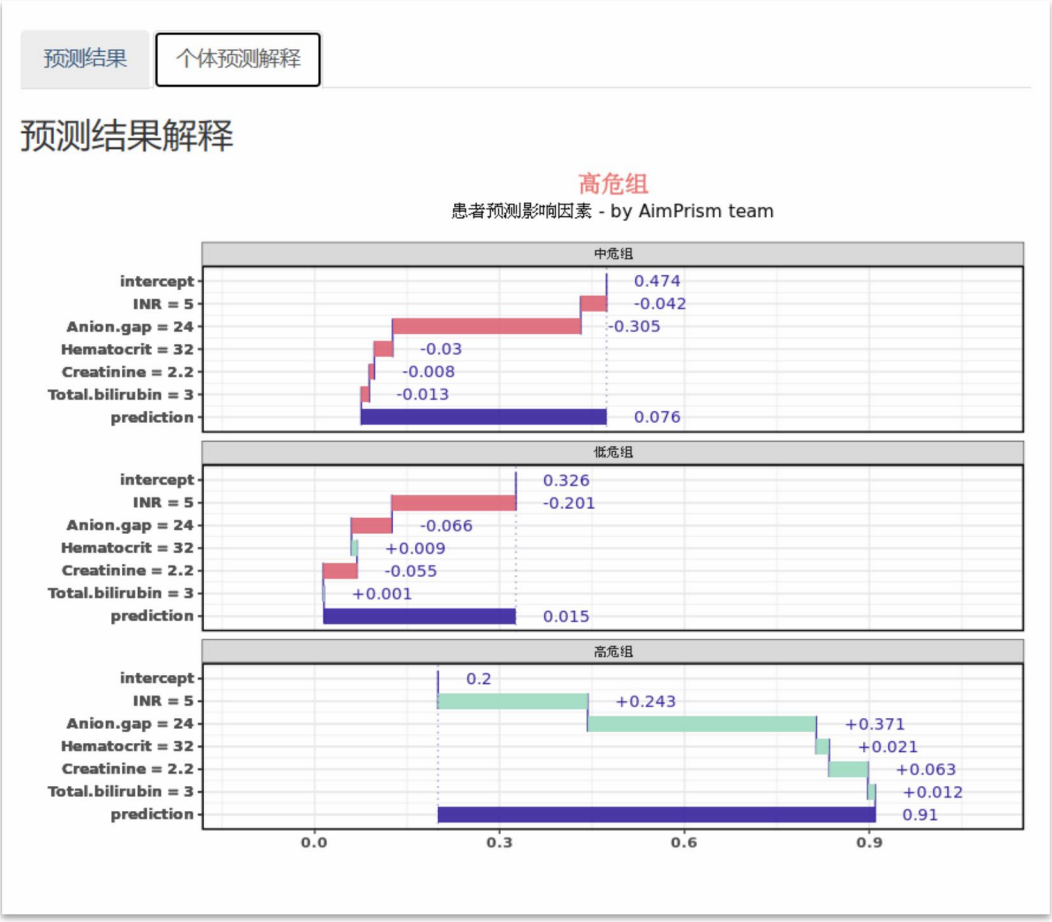

图 19 在线部署模型个体化决策依据示意图

讨 论

本研究基于无监督聚类分析及机器学习算法，利用多数据库队列联合真实世界数据，成功识别出肝硬化合并脓毒血症患者中的三类亚组（高危、中危、低危），并构建了便于临床应用的亚组早期预测模型。

亚组患者的识别，尤其是预后较差的高危亚组的精准划分，是近年来精准医疗领域的研究热点[22]。近年来，随着无监督聚类分析在医学各领域的广泛应用，大量疾病的全新亚组被发现。例如，Christopher 等研究者基于 k 均值无监督聚类法方法，利用脓毒血症患者入院时的临床数据，识别出四种独特的亚组：α亚组（使用血管加压药给药量最低），β亚组（年龄较大且慢性疾病和肾功能不全更为常见），γ亚组（炎症水平较高且伴随显著的肺功能障碍）与 δ亚组（肝功能损伤严重且感染性休克发生率更高）[23]。类似地，Dong 等研究者亦采用 k 均值无监督聚类法方法，基于 KORA 队列数据，发现二型糖尿病的三种独特亚组，其特征分别为胰岛素抵抗伴高神经病变患病率、高龄以及与遗传和肥胖高度相关[24]。在肝脏疾病领域，目前的研究主要聚焦于分子亚型的基础研究。Ding 等研究者通过无监督学习方式，结合临床、遗传、酒精暴露和血清代谢组学的综合分析，揭示了中国人群中非酒精性脂肪性肝病的三种独特分子亚组，其特征分别为 CYP1A2 和 CYP3A4 表达水平升高、M1 和 M2 巨噬细胞在肝脏中的浸润增加，以及 CEBPB 和 ERCC3 调控的癌基因转录活性增强[25]。然而，针对肝硬化疾病，尤其是肝硬化合并脓毒血症患者的亚组识别，目前的研究仍十分有限。本研究立足于临床实际问题，通过无监督聚类算法成功识别出预后差异显著的三类亚组患者：高危、中危和低危组。高危组患者以内环境紊乱和严重多脏器功能损伤（肝脏及肾脏）为主要特征，表现为更为显著的代谢失衡和器官功能障碍。相比之下，中危组与低危组患者呈现出改善的内环境状态，但中危组患者的凝血功能损伤程度较低危组更为严重。

基于不同亚组分类，现代医学能够为患者提供更加个性化的治疗策略，从而显著改善预后。本研究聚焦于早期白蛋白输注策略对肝硬化合并脓毒血症患者预后的影响。研究结果显示，在第一日使用白蛋白与不良预后之间存在显著关联。即便通过倾向性评分匹配分析控制了协变量后，虽然这一关联不再具有统计学显著性，但仍呈现出相

同的趋势。这一现象可能归因于高危亚组患者在入院初期难以耐受综合治疗，从而面临较高的早期死亡风险（示意图 6 揭示了这一点）。具体而言，高危亚组患者通常伴有严重的内环境紊乱和多器官功能障碍，其脆弱的生理状态可能使其无法承受包括白蛋白输注在内的早期积极干预措施。这种不耐受性可能导致病情迅速恶化，甚至在入院初期即出现快速死亡。然而，值得注意的是，第二日与第三日的白蛋白输注对高危患者表现出显著的保护作用，可有效改善预后。相比之下，对于中危组和低危组患者，白蛋白输注并未对预后产生显著影响。因此，在临床实践中，针对这两类患者，白蛋白输注可根据实际病情状况选择性使用，而非作为常规治疗手段。

不同亚组患者临床基线数据的显著差异为肝硬化合并脓毒血症患者亚组分类的潜在异质性机制提供了初步解释。在此基础上，本研究构建了亚组早期预测模型，其核心目标不仅在于实现高危亚组患者的早期识别，还旨在通过机器学习算法可解释性算法挖掘影响亚组异质性的关键临床变量。在疾病预测领域，机器学习凭借其对非线性关系的建模能力，已成为近年来的研究热点。相较于传统回归模型，机器学习在处理复杂数据结构（如非线性变量-结局关系）时表现出显著优势，尤其在急性胰腺炎等异质性较强的疾病中，其预测性能通常更优[26–29]。在肝硬化相关疾病的研究中，机器学习的应用也取得了重要进展。例如，Vivek 团队基于 23 项人口学和临床变量，开发了一种集成机器学习模型，用于预测非酒精性肝病患者的肝纤维化风险。该模型在外部验证集中的 AUC 达到 0.79 （95% CI: 0.73-0.84），展现出良好的预测性能[30]。此外，Guo 等研究者利用英国生物银行中 64005 名患者的代谢组学数据，构建了肝硬化患者远期并发症的机器学习预测模型。该模型显著提高了肝脏相关事件的风险分层能力，并为个性化管理提供了有力支持[31]。本研究通过比较 8 种机器学习算法，结合交叉验证及超参数随机搜索优化技术，最终构建了综合性能最优的随机森林预测模型。该模型在预测肝硬化合并脓毒血症亚组方面表现优异，不仅具有较高的准确性，还展现出良好的泛化能力，为临床实践中的早期干预提供了重要的工具支持。

通过机器学习模型可解释性算法，本研究在一定程度上进一步发现了肝硬化合并脓毒血症患者亚组异质性的影响变量。阴离子间隙被识别为区分亚组的最重要变量。阴离子间隙是指血浆中未测定阴离子与未测定阳离子浓度之间的差值，广泛用于评估患者的酸碱平衡状态[32,32]。本研究发现，随着阴离子间隙数值的升高，患者更倾向于被归类为高危亚组。这一现象可能与肝硬化合并脓毒血症患者的病理生理变化密切相

关。在病情相对稳定的肝硬化患者中，尽管存在多种酸化和碱化代谢紊乱，但整体酸碱平衡通常能够维持相对稳定。然而，当患者遭受脓毒血症的急性打击时，这种脆弱的平衡往往被打破，并倾向于发展为以阴离子间隙升高为特征的代谢性酸中毒，这种酸中毒主要由乳酸酸中毒和未测定阴离子增加所驱动，尽管肝硬化患者常见的低白蛋白血症可能通过引发碱中毒部分抵消酸中毒的影响，但在高危亚组患者中，这种代偿机制似乎难以完全发挥作用，导致酸碱失衡进一步加剧[33–36]。此外，红细胞比容也被认为是重要的亚组分组影响因素，尤其是在区分中危与低危亚组患者时具有显著作用。红细胞比容是反映红细胞与血浆比例的常用参数，既往研究已表明其降低与脓毒血症患者的不良预后密切相关[37]。在肝硬化背景下，门静脉高压症引起的急性或慢性出血、造血原料代谢异常等病理生理改变可能进一步加剧红细胞比容对患者预后的影响[38–40]。机器学习模型的可解释性算法进一步揭示，INR、肌酐和总胆红素是影响患者亚组分类的因素。这些指标分别从不同维度反映了患者的病理生理状态：INR 体现了凝血功能的紊乱程度，肌酐反映了肾功能的状态，而总胆红素则揭示了肝脏代谢与排泄功能的受损情况，这一发现与既往大量研究结果高度一致[41–44]。

本研究存在一定的局限性，需在未来的研究中加以改进。首先，亚组识别基于回顾性数据分析，尽管通过多种统计方法尽可能控制了混杂因素的影响，但选择偏倚仍难以完全避免。其次，由于数据库内容的限制，本研究未能进一步根据患者的病理类型对亚组分型及治疗策略进行深入探讨。此外，本研究的真实世界队列（苏州队列）样本量相对有限，仅能用于早期亚组预测模型性能的验证，而无法在真实世界层面再次推导和验证亚组分型。这一限制可能对研究结论的外部有效性产生一定影响。因此，未来需要更大规模的前瞻性研究，以进一步验证本研究的发现。

综上所述，本研究基于无监督聚类分析与机器学习技术，成功识别出肝硬化合并脓毒血症患者的三种独特亚组，并针对白蛋白早期输注策略提供了临床建议。此外，本研究还开发并部署了亚组早期预测模型，旨在提高研究成果在临床实践中的应用价值。

结　论

本研究利用多数据库联合真实世界队列，通过无监督聚类算法探究了肝硬化合并脓毒血症亚组临床特点、预后及早期白蛋白输注策略对其影响。基于机器学习模型，开发验证并部署了可解释的亚组早期预测模型，提高临床实践。具体而言：1）1）研究识别出三种具有不同预后的亚组，其中高危组表现出严重的内环境紊乱及多器官损伤。中危组和低危组的内环境紊乱及器官损伤情况较之高危组有显著改善，且两者之间无明显差异；然而，中危组患者的凝血功能相较于低危组更差。2）对于高危组患者，入院第二日和第三日输注白蛋白对其预后具有显著的保护作用；而对于中危组和低危组患者，未发现早期输注白蛋白带来的明显益处。3）研究基于红细胞比容、国际标准化比值、阴离子间隙、肌酐以及总胆红素等变量构建并验证了亚组早期预测模型，并将其成功部署至在线平台以供使用。

参考文献

[1] Ginès P, Krag A, Abraldes J G, et al. Liver cirrhosis[J]. Lancet (London, England), 2021, 398(10308): 1359-1376.

[2] Huang D Q, Terrault N A, Tacke F, et al. Global epidemiology of cirrhosis — aetiology, trends and predictions[J]. Nature Reviews. Gastroenterology & Hepatology, 2023, 20(6): 388-398.

[3] Liu Y B, Chen M K. Epidemiology of liver cirrhosis and associated complications: Current knowledge and future directions[J]. World Journal of Gastroenterology, 2022, 28(41): 5910-5930.

[4] Kolodyazhna A, Wiersinga W J, Van der Poll T. Aiming for precision: personalized medicine through sepsis subtyping[J]. Burns & Trauma, 2025, 13: tkae073.

[5] Tapper E B, Parikh N D. Diagnosis and Management of Cirrhosis and Its Complications: A Review[J]. JAMA, 2023, 329(18): 1589-1602.

[6] Gustot T, Durand F, Lebrec D, et al. Severe sepsis in cirrhosis[J]. Hepatology (Baltimore, Md.), 2009, 50(6): 2022-2033.

[7] Arvaniti V, D'Amico G, Fede G, et al. Infections in patients with cirrhosis increase mortality four-fold and should be used in determining prognosis[J]. Gastroenterology, 2010, 139(4): 1246-1256, 1256.e1-5.

[8] Piano S, Tonon M, Angeli P. Changes in the epidemiology and management of bacterial infections in cirrhosis[J]. Clinical and Molecular Hepatology, 2021, 27(3): 437-445.

[9] Gustot T, Felleiter P, Pickkers P, et al. Impact of infection on the prognosis of critically ill cirrhotic patients: results from a large worldwide study[J]. Liver International: Official Journal of the International Association for the Study of the Liver, 2014, 34(10): 1496-1503.

[10] North Italian Endoscopic Club for the Study and Treatment of Esophageal Varices. Prediction of the first variceal hemorrhage in patients with cirrhosis of the liver and esophageal varices. A prospective multicenter study[J]. The New England Journal of Medicine, 1988, 319(15): 983-989.

[11] Kamath P S, Wiesner R H, Malinchoc M, et al. A model to predict survival in patients

with end-stage liver disease[J]. Hepatology (Baltimore, Md.), 2001, 33(2): 464-470.

[12] Kim W R, Mannalithara A, Heimbach J K, et al. MELD 3.0: The Model for End-Stage Liver Disease Updated for the Modern Era[J]. Gastroenterology, 2021, 161(6): 1887-1895.e4.

[13] MIMIC-IV, a freely accessible electronic health record dataset | Scientific Data[EB].

[14] Pollard T J, Johnson A E W, Raffa J D, et al. The eICU Collaborative Research Database, a freely available multi-center database for critical care research[J]. Scientific Data, 2018, 5(1): 180178.

[15] Singer M, Deutschman C S, Seymour C W, et al. The Third International Consensus Definitions for Sepsis and Septic Shock (Sepsis-3)[J]. JAMA, 2016, 315(8): 801-810.

[16] Extensions to the k-Means Algorithm for Clustering Large Data Sets with Categorical Values | Data Mining and Knowledge Discovery[EB].

[17] Uniform manifold approximation and projection | Nature Reviews Methods Primers[EB].

[18] Durand F, Kellum J A, Nadim M K. Fluid resuscitation in patients with cirrhosis and sepsis: A multidisciplinary perspective[J]. Journal of Hepatology, 2023, 79(1): 240-246.

[19] Maiwall R, Kumar A, Pasupuleti S S R, et al. A randomized-controlled trial comparing 20% albumin to plasmalyte in patients with cirrhosis and sepsis-induced hypotension [ALPS trial][J]. Journal of Hepatology, 2022, 77(3): 670-682.

[20] Philips C A, Maiwall R, Sharma M K, et al. Comparison of 5% human albumin and normal saline for fluid resuscitation in sepsis induced hypotension among patients with cirrhosis (FRISC study): a randomized controlled trial[J]. Hepatology International, 2021, 15(4): 983-994.

[21] Evans L, Rhodes A, Alhazzani W, et al. Surviving sepsis campaign: international guidelines for management of sepsis and septic shock 2021[J]. Intensive Care Medicine, 2021, 47(11): 1181-1247.

[22] Shivade C, Raghavan P, Fosler-Lussier E, et al. A review of approaches to identifying patient phenotype cohorts using electronic health records[J]. Journal of the American Medical Informatics Association: JAMIA, 2014, 21(2): 221-230.

[23] Seymour C W, Kennedy J N, Wang S, et al. Derivation, Validation, and Potential Treatment Implications of Novel Clinical Phenotypes for Sepsis[J]. JAMA, 2019,

321(20): 2003-2017.

[24] Q D, Y X, S B, et al. Subphenotypes of adult-onset diabetes: Data-driven clustering in the population-based KORA cohort[J]. Diabetes, obesity & metabolism, 2025, 27(1).

[25] Ding J, Liu H, Zhang X, et al. Integrative multiomic analysis identifies distinct molecular subtypes of NAFLD in a Chinese population[J]. Science Translational Medicine, 2024, 16(772): eadh9940.

[26] Sidey-Gibbons J A M, Sidey-Gibbons C J. Machine learning in medicine: a practical introduction[J]. BMC medical research methodology, 2019, 19(1): 64.

[27] Zhou Y, Ge Y T, Shi X L, et al. Machine learning predictive models for acute pancreatitis: A systematic review[J]. International Journal of Medical Informatics, 2022, 157: 104641.

[28] Langmead C, Lee P J, Paragomi P, et al. A Novel 5-Cytokine Panel Outperforms Conventional Predictive Markers of Persistent Organ Failure in Acute Pancreatitis[J]. Clinical and Translational Gastroenterology, 2021, 12(5): e00351.

[29] Fei Y, Gao K, Li W Q. Artificial neural network algorithm model as powerful tool to predict acute lung injury following to severe acute pancreatitis[J]. Pancreatology: official journal of the International Association of Pancreatology (IAP) ... [et al.], 2018, 18(8): 892-899.

[30] Charu V, Liang J W, Mannalithara A, et al. Benchmarking clinical risk prediction algorithms with ensemble machine learning for the noninvasive diagnosis of liver fibrosis in NAFLD[J]. Hepatology (Baltimore, Md.), 2024, 80(5): 1184-1195.

[31] Guo C, Liu Z, Fan H, et al. Machine-learning-based plasma metabolomic profiles for predicting long-term complications of cirrhosis[J]. Hepatology (Baltimore, Md.), 2025, 81(1): 168-180.

[32] Kraut J A, Madias N E. Serum anion gap: its uses and limitations in clinical medicine[J]. Clinical journal of the American Society of Nephrology: CJASN, 2007, 2(1): 162-174.

[33] Scheiner B, Lindner G, Reiberger T, et al. Acid-base disorders in liver disease[J]. Journal of Hepatology, 2017, 67(5): 1062-1073.

[34] Nanji A A, Campbell D J, Pudek M R. Decreased anion gap associated with hypoalbuminemia and polyclonal gammopathy[J]. JAMA, 1981, 246(8): 859-860.

[35] Katopodis P, Pappas E M, Katopodis K P. Acid-base abnormalities and liver

dysfunction[J]. Annals of Hepatology, 2022, 27(2): 100675.

[36] Drolz A, Horvatits T, Roedl K, et al. Acid-base status and its clinical implications in critically ill patients with cirrhosis, acute-on-chronic liver failure and without liver disease[J]. Annals of Intensive Care, 2018, 8(1): 48.

[37] Luo M, Chen Y, Cheng Y, et al. Association between hematocrit and the 30-day mortality of patients with sepsis: A retrospective analysis based on the large-scale clinical database MIMIC-IV[J]. PloS One, 2022, 17(3): e0265758.

[38] Gonzalez-Casas R, Jones E A, Moreno-Otero R. Spectrum of anemia associated with chronic liver disease[J]. World Journal of Gastroenterology, 2009, 15(37): 4653-4658.

[39] Paternostro R, Kapzan L, Mandorfer M, et al. Anemia and iron deficiency in compensated and decompensated cirrhosis: Prevalence and impact on clinical outcomes[J]. Journal of Gastroenterology and Hepatology, 2020, 35(9): 1619-1627.

[40] Muro N, Bujanda L, Sarasqueta C, et al. [Plasma levels of folate and vitamin B(12) in patients with chronic liver disease][J]. Gastroenterologia Y Hepatologia, 2010, 33(4): 280-287.

[41] Kim H J, Lee H W. Important predictor of mortality in patients with end-stage liver disease[J]. Clinical and Molecular Hepatology, 2013, 19(2): 105-115.

[42] Wong F, O'Leary J G, Reddy K R, et al. Acute Kidney Injury in Cirrhosis: Baseline Serum Creatinine Predicts Patient Outcomes[J]. The American Journal of Gastroenterology, 2017, 112(7): 1103-1110.

[43] López-Velázquez J A, Chávez-Tapia N C, Ponciano-Rodríguez G, et al. Bilirubin alone as a biomarker for short-term mortality in acute-on-chronic liver failure: an important prognostic indicator[J]. Annals of Hepatology, 2013, 13(1): 98-104.

[44] Fierro-Angulo O M, González-Regueiro J A, Pereira-García A, et al. Hematological abnormalities in liver cirrhosis[J]. World Journal of Hepatology, 2024, 16(9): 1229-1244.

综 述

机器学习在肝硬化及相关并发症领域研究进展

摘要：多种肝脏疾病终末阶段共同表现的肝硬化，已成为全球范围内的重要公共卫生问题。随肝硬化病程进一步发展，其失代偿期一系列的并发症，如门静脉高压引发的食管胃底静脉曲张破裂出血、肝细胞癌、腹水、肝性脑病、脓毒血症等显著降低了患者生活治疗及长期预后。目前，利用以大数据驱动为核心的机器学习技术，已被证实可在医学领域改善疾病的预测和管理。本文旨在系统全面的总结述理机器学习技术在肝硬化及其并发症领域的应用，为临床医生和研究人员提供最新的研究进展和循证依据。

关键词：肝硬化，脓毒血症，机器学习，人工智能

引 言

肝硬化是多种慢性肝脏疾病的终末阶段，其病理特征表现为肝细胞广泛坏死、纤维组织增生及再生结节形成[1]。在全球范围内，肝硬化现已是全球第十一大死亡原因，成为了重要的公共卫生问题[2]。在病因方面，不同地区存在显著差异：在亚洲，乙型肝炎病毒感染是肝硬化的主要致病因素；而在欧美国家，酒精性肝病和代谢功能障碍相关脂肪性肝病（Metabolic Dysfunction-Associated Steatotic Liver Disease, MASLD）则是主要病因[3,4]。

肝硬化的病程通常分为代偿期和失代偿期两个阶段[5]。代偿期患者通常无明显症状或仅表现出轻微症状，而失代偿期则以一系列并发症为标志，包括门静脉高压引发的食管胃底静脉曲张破裂出血、肝细胞癌、腹水、肝性脑病、脓毒血症等[6]。肝硬化相关并发症显著降低了患者生存质量同时，也影响了患者生存预后[7]。既往研究表明，一旦肝硬化患者出现相关并发症，进入失代偿期，其 5 年生存率将从代偿期的 80-85% 显著降至 14-35%[8]。因此，及早识别高风险患者，预测并发症发生，实施有效干预措施，对改善肝硬化患者预后至关重要。

传统评分，如 Child-Pugh 评分和 MELD 系列评分已被广泛用于评估肝硬化患者

的疾病严重程度和预后。Child-Pugh 评分基于五个临床指标（腹水、肝性脑病、胆红素、白蛋白以及凝血酶原时间），将患者分为 A、B、C 三个不同危险等级，但其主观性强、区分度有限且未能考虑其他重要器官的功能状态[9]。MELD 系列评分基于客观实验室指标，并在临床实践中不断更新优化[10]。最新的 MELD 3.0 评分进一步扩展了变量范围，纳入了性别、胆红素、钠离子、国际标准化比值（International Normalized Ratio，INR）、肌酐和白蛋白等指标，进一步提升了对患者整体预后的评估精度。但其对相关并发症的预测能力仍然有限[11]。此外，这些传统评分系统都是基于线性模型构建，难以捕捉复杂的非线性关系和高维数据中的隐藏模式，无法满足个体化精准医疗的需求。

近年来，得益于现代医疗模式爆发式增长的临床数据，机器学习在医学各领域的应用日益广泛[12]。与传统统计学方法侧重于“推理”（即通过代表性样本来推断群体特征）不同，机器学习更注重“预测”，其核心目标是通过对大数据的挖掘实现精准预测，而非仅仅关注样本本身的特性。以数据驱动为核心的特性，使机器学习在处理高维复杂数据、识别非线性关系、自动特征提取以及动态优化更新等方面展现出显著优势。

本研究旨在全面系统地梳理机器学习技术在肝硬化及其主要并发症预测和管理方面的最新研究进展，为临床医生和研究人员提供最新的研究进展和循证依据，促进机器学习技术在肝硬化及其并发症领域的应用，改善患者管理和预后。

1.机器学习技术分类概述

机器学习是数学、统计学和计算机科学的有机结合，其核心在于通过算法从数据中提取模式并进行预测或分类。根据是否涉及数据的结局标签（即目标变量），机器学习通常可分为监督式学习、无监督式学习和半监督式学习三大类。

监督式机器学习是指在已知数据结局标签的情况下，利用输入特征对模型进行训练，从而实现对未知数据的预测。在医学领域，监督式学习常被应用于基于回顾性研究的数据分析。例如利用患者的临床基线数据（如实验室指标、影像学特征等）预测疾病诊断结果或患者预后[13,14]。但监督式学习依赖于高质量的标注数据，且可能存在过度拟合的风险，影响模型的泛化能力。

与监督式机器学习相比，无监督机器学习不依赖数据标签，即在无人为干预的情况下探索性地挖掘数据的潜在分布模式。医学中常使用无监督机器学习识别疾病的潜

在亚组或患者分型。例如，通过对基因表达数据或临床特征的聚类分析，可以揭示疾病的异质性，为精准医疗提供依据[15]。这种方法尤其适用于缺乏明确标签但数据维度较高的场景。

介于监督式学习和无监督学习之间，半监督式机器学习利用少量具有结局标签的数据和大量未标注数据共同训练模型，从而在降低数据标注成本的同时提高模型性能。近年来，随着深度学习和大语言模型在医学领域的研究不断深入，半监督学习已被广泛应用于减少医疗数据标注的工作量[16]。

2.机器学习在肝硬化及相关并发症领域研究

2.1 肝硬化及纤维化

肝硬化及纤维化的诊断金标准为病理活检，但由于其侵入性操作对患者可能造成的损伤，临床应用中存在一定局限性。近年来，随着机器学习技术的快速发展，基于结构化和非结构化数据的非侵入性预测方法及模型在肝硬化及肝纤维化中的应用日益广泛。基于结构化数据，Chang 等研究者利用 Logistic 回归、随机森林和人工神经网络，基于 17 个与人口学信息和临床特征相关的变量，构建了肝纤维化预测模型。该模型在经过病理验证的独立人群中进行性能评估时，表现优于传统的纤维化评分系统（如 FIB-4 评分）及肝脏超声弹性成像检测评估[17]。类似的研究还有 Fan 等人通过结合肝脏超声弹性检测结果和患者临床指标（包括年龄、性别、白蛋白、胆红素和血小板计数) 的机器学习算法，于 946 名来自中国和美国 MASLD 患者中开发并验证了纤维化及肝硬化预测模型，其准确性可达 91.2%与 96.8%[18]。除了结构化数据，基于非结构化数据（如医学影像）的机器学习模型也展现出巨大潜力。Sebastian 等研究者基于 713 名患者的肝脏 T2 加权核磁共振图像数据，利用迁移学习策略，开发了以 ResNet50 卷积神经网络为骨干的肝硬化分类模型。该模型在与资深影像科医师的诊断准确率对比中表现出更高的性能[19]。 采用多模态数据，Nikhilesh 等人利用深度学习分割模型（UNet 和 DeepLabv3+算法），基于 1590 名患者的 CT（Computed Tomography）扫描数据集，训练了一个自动肝脏分割及特征提取模型。通过整合常规实验室数据和人口统计学信息，成功开发了肝硬化多模态预测模型。该模型在 352 名患者（包括 72 名肝移植受者）的验证队列中取得了 0.85 的 AUC（Area Under Curve）值，显示出较高的预测能力[20]。

除肝硬化及纤维化预测外，由于肝硬化病程呈进行性发展，其死亡风险预测也一直为研究热点。Fasiha 等研究者基于一个大样本队列（包含 107939 名患者），利用三种机器学习模型，包括梯度下降提升模型，LASSO（Least Absolute Shrinkage And Selection Operator）正则化的 Logistic 回归模型与部分路径 Logistic 回归模型，开发了肝硬化死亡预测模型[21]。与传统的 MELD-Na 评分（AUC = 0.67，95% 置信区间：0.66 - 0.68）相比，这三种模型在一年死亡率预测方面均表现出更高的效能：梯度提升决策树模型（AUC = 0.81，95% 置信区间：0.80 - 0.82）、LASSO 正则化的 Logistic 回归模型（AUC = 0.78，95% 置信区间：0.77 - 0.79）以及部分路径 Logistic 回归模型（AUC = 0.78，95% 置信区间：0.76 - 0.78）。针对疾病进展更为迅速的终末期肝病患者，Lin 等研究者基于中国台湾两家独立医院的队列数据（分别为 907 名和 643 名患者），开发并验证了一种随机森林预测模型，用于评估非肿瘤性终末期肝硬化患者的死亡风险。该模型在验证集中的表现优于传统评分系统，其 AUC 值达到 0.85，显著高于 MELD 评分（AUC = 0.76）和 MELD-Na 评分（AUC = 0.79）。此外，通过可解释性算法分析，研究发现血尿素氮、胆红素和钠离子是预测死亡率的关键因素[22]。

2.2 门静脉高压及食管胃底静脉出血

既往研究表明，对门静脉高压患者进行早期积极干预（如使用非选择性 β 受体阻滞剂，包括卡维地洛或普萘洛尔），可显著降低肝硬化失代偿事件的发生率及患者死亡风险[23]。因此，门静脉高压的早期识别与危险程度分级颇显重要。目前，肝静脉压力梯度测量是诊断门静脉高压的金标准，但其侵入性操作和对专业设备及技术的依赖性，限制了其在临床实践中的广泛应用，凸显了对可靠的非侵入性方案的需求。

Reinis 等人提出了一种基于常见实验室参数（包括血小板计数、总胆红素、胆碱酯酶、γ-谷氨酰转移酶和部分凝血活酶时间）的机器学习模型，用于预测肝硬化代偿期患者的门静脉高压严重程度。该模型在验证集中的 AUC 值达到 0.813，显著优于肝脏超声弹性检测的结果（AUC = 0.808）[24]。采用医学影像等非结构化数据似乎能够进一步提升预测能力。Liu 等研究者基于一个包含 385 名患者的多中心前瞻性队列（涵盖 5 个研究中心），开发了一种基于 CT 图像的非侵入性放射组学预测模型。该模型在四个外部验证队列中表现出色，其 AUC 值分别为 0.889（95%置信区间：0.752 – 1.000）、0.800（95%置信区间：0.614 – 0.986）、0.917（95%置信区间：0.772 – 1.000）

和 0.827（95%置信区间：0.618－1.000）[25]。进一步拓展这一方向，Wang 等研究者融合了多模态影像学数据（包括增强 CT 和核磁共振），通过提取门静脉、肝静脉、主动脉和下腔静脉中的多种血管参数，构建了门静脉高压预测模型。该模型在内部测试集中达到了 0.90 的 AUC 值，显示出更高的预测精度[26]。基于模型的可解释性算法分析，研究发现门静脉高压患者的肝脏血管分布密度显著降低，尤其是远端血管的丰度明显减少。这一发现不仅为模型提供了生物学解释依据，也为理解门静脉高压的病理生理机制提供了新的视角。

食管胃底静脉曲张是门静脉高压进展中最常见的临床表现，其破裂出血被认为是肝硬化患者最为凶险的并发症之一。目前，机器学习在食管胃底静脉曲张领域的研究主要集中在高危人群的出血风险预测以及再出血风险评估。Zhao 等研究者提出了一种基于 CT 形态学测量、血清生物标志物和患者年龄的自适应增强算法模型，用于预测食管胃底静脉曲张的发生。该模型在验证集中的 AUC 值达到 0.804，显示出较高的预测效能[27]。Liu 等研究者利用极端梯度提升算法，基于肝脏硬度测量结果和实验室指标，开发了食管胃底静脉曲张再出血风险预测模型。该模型在预测乙型肝炎相关门静脉高压患者 6 周和 1 年再出血风险时表现出优异性能，其准确性分别达到 0.985 和 0.931，显著高于 Logistic 回归模型（分别为 0.828 和 0.799）[28]。

2.3 肝细胞癌

肝细胞癌是最常见的原发性肝癌类型，同时也是全球癌症相关死亡的第三大原因[29]。由于其发病隐匿且常规治疗手段的效果有限，多数患者在确诊时已处于晚期，导致其 5 年生存率仅为 15%[30]。既往研究表明，与肝硬化相关的肝细胞癌死亡率正在逐年上升，并已成为代偿性肝硬化患者肝病相关死亡的主要原因[31]。因此，早期识别肝细胞癌高危的肝硬化患者并优化其医疗管理，对于改善预后具有重要意义。

机器学习已被证明可有效预测肝硬化患者发生肝细胞癌的风险。Amit 等研究者在一个包含 442 名 Child-Pugh A 级和 B 级患者的队列中，比较了传统回归模型与机器学习模型在划分肝细胞癌风险方面的性能。研究结果显示，传统回归模型的 C 统计量为 0.61（95% 置信区间：0.56－0.67），而机器学习模型的 C 统计量提升至 0.64（95% 置信区间：0.60－0.69），展示了机器学习的价值[32]。Kin 等研究者进一步扩大了样本量，在一项涵盖 6051 名韩国乙型肝炎病毒感染相关肝硬化患者的研究中，

基于 10 个临床变量，利用梯度提升算法开发了一种机器学习模型。该模型在不同人群中的验证表现优异：在韩国验证队列中，其 C 指数达到 0.79；在高加索人群验证队列中，C 指数进一步提升至 0.81[33]。

2.4 肝硬化其余相关并发症

机器学习通过提供非侵入性和个性化医疗的方式，为顽固性腹水的管理带来了新的可能性。Silvia 等研究者开发了一种基于 LASSO 回归的预测模型，该模型整合了 34 个常见的临床变量，用于识别感染性腹水患者。在一系列验证测试中，该模型表现出较高的特异性，表明其可作为腹腔穿刺术的一种可靠无创替代方案[34]。Behzad 等研究者利用多种机器学习算法（包括 k 近邻算法、支持向量机和人工神经网络），基于常规临床数据构建了腹水分级预测模型。其中，k 近邻算法模型的表现最为突出，其预测准确性高达 94%，显著优于其他算法[35]。

肝性脑病在我国肝硬化住院患者中的发病率高达 39.9%，其早期识别与干预对于降低患者死亡率具有重要意义[36,37]。在一项基于重症医疗数据库的回顾性研究中，Yang 等研究者开发并验证了一系列机器学习模型，用于预测肝性脑病患者的早期死亡率。这些模型包括 Logistic 回归、加权随机森林以及加权支持向量机。加权随机森林模型相较其余模型表现更佳，在验证集中的 AUC 值达到 0.76，显示出较高的预测效能[38]。Shanmugha Priya 等研究者采用了更为复杂的脉冲神经网络算法，基于 CT 图像实现了正常个体与肝性脑病患者的分类。该脉冲神经网络模型的分类准确率高达 96.29%，相较于支持向量机模型、ResNet50 卷积神经网络模型以及 MELD 评分，分别提升了 25.3%、2.74%和 31.4%的总体准确率[39]。

在肝硬化合并脓毒血症的研究领域，机器学习的应用尚处于起步阶段，相关研究极为有限。既往研究主要聚焦于探索与预后不良相关的因素，例如病理学中性粒细胞迁移异常、阴离子间隙升高以及乳酸与白蛋白比值的变化等生物标志物[40–42]。这些研究多基于传统统计方法，缺乏对复杂数据模式的深入挖掘。回顾现有文献，仅有 Mathew 等研究者在儿童肝硬化群体中开展了相关探索。他们利用血浆代谢组学和代谢蛋白质组学变量，构建了一种用于预测儿童肝硬化合并脓毒血症患者早期死亡风险的机器学习模型[43]。但在成人肝硬化合并脓毒血症的研究，目前仍存在显著的研究空白。

结 论

随着现代医学的快速发展，海量诊疗数据的积累以及计算机硬件和软件技术的进步，机器学习正逐步成为实现个体化精准医疗不可或缺的重要工具。在肝硬化及其并发症的研究与临床应用中，机器学习已展现出巨大的潜力，为疾病的预测、诊断和管理提供了创新性解决方案。然而，随着机器学习技术的广泛应用，其潜在的伦理和技术挑战也不容忽视。例如，海量医疗数据的使用可能带来患者隐私泄露的风险，而算法决策的透明性和可解释性不足也可能引发医疗责任界定的争议。这些问题不仅涉及技术层面，还关乎伦理、法律和社会接受度，值得进一步深入探讨和审慎应对。

参考文献

[1] Garcia-Tsao G, Friedman S, Iredale J, et al. Now there are many (stages) where before there was one: In search of a pathophysiological classification of cirrhosis[J]. Hepatology (Baltimore, Md.), 2010, 51(4): 1445-1449.

[2] Asrani S K, Devarbhavi H, Eaton J, et al. Burden of liver diseases in the world[J]. Journal of Hepatology, 2019, 70(1): 151-171.

[3] Wang F S, Fan J G, Zhang Z, et al. The global burden of liver disease: the major impact of China[J]. Hepatology (Baltimore, Md.), 2014, 60(6): 2099-2108.

[4] Tham E K J, Tan D J H, Danpanichkul P, et al. The Global Burden of Cirrhosis and Other Chronic Liver Diseases in 2021[J]. Liver International: Official Journal of the International Association for the Study of the Liver, 2025, 45(3): e70001.

[5] Tsochatzis E A, Bosch J, Burroughs A K. Liver cirrhosis[J]. Lancet (London, England), 2014, 383(9930): 1749-1761.

[6] Tapper E B, Parikh N D. Diagnosis and Management of Cirrhosis and Its Complications: A Review[J]. JAMA, 2023, 329(18): 1589-1602.

[7] Tapper E B, Kanwal F, Asrani S K, et al. Patient-reported outcomes in cirrhosis: A scoping review of the literature[J]. Hepatology (Baltimore, Md.), 2018, 67(6): 2375-2383.

[8] D'Amico G, Garcia-Tsao G, Pagliaro L. Natural history and prognostic indicators of survival in cirrhosis: a systematic review of 118 studies[J]. Journal of Hepatology, 2006, 44(1): 217-231.

[9] Kaplan D E, Dai F, Aytaman A, et al. Development and Performance of an Algorithm to Estimate the Child-Turcotte-Pugh Score From a National Electronic Healthcare Database[J]. Clinical Gastroenterology and Hepatology: The Official Clinical Practice Journal of the American Gastroenterological Association, 2015, 13(13): 2333-2341.e1-6.

[10] Kamath P S, Wiesner R H, Malinchoc M, et al. A model to predict survival in patients with end-stage liver disease[J]. Hepatology (Baltimore, Md.), 2001, 33(2): 464-470.

[11] Kim W R, Mannalithara A, Heimbach J K, et al. MELD 3.0: The Model for End-Stage Liver Disease Updated for the Modern Era[J]. Gastroenterology, 2021, 161(6): 1887-1895.e4.

[12] Rajkomar A, Dean J, Kohane I. Machine Learning in Medicine[J]. The New England

Journal of Medicine, 2019, 380(14): 1347-1358.

[13] Zheng W, Zhu S, Wang X, et al. Machine learning for early diagnosis of Kawasaki disease in acute febrile children: retrospective cross-sectional study in China[J]. Scientific Reports, 2025, 15(1): 6799.

[14] Qi Y, Hu Y, Lin C, et al. A preoperative predictive model based on multi-modal features to predict pathological complete response after neoadjuvant chemoimmunotherapy in esophageal cancer patients[J]. Frontiers in Immunology, 2025, 16: 1530279.

[15] Wang Y, Wen Q, Lian X, et al. Machine learning-based unsupervised phenotypic clustering analysis of patients with IgA nephropathy: Distinct therapeutic responses of different groups[J]. Chinese Medical Journal, 2025.

[16] Li H, Yin D, Li B, et al. A novel semi-supervised learning model based on pelvic radiographs for ankylosing spondylitis diagnosis reduces 90% of annotation cost[J]. Computers in Biology and Medicine, 2025, 184: 109232.

[17] Chang D, Truong E, Mena E A, et al. Machine learning models are superior to noninvasive tests in identifying clinically significant stages of NAFLD and NAFLD-related cirrhosis[J]. Hepatology (Baltimore, Md.), 2023, 77(2): 546-557.

[18] Fan R, Yu N, Li G, et al. Machine-learning model comprising five clinical indices and liver stiffness measurement can accurately identify MASLD-related liver fibrosis[J]. Liver International: Official Journal of the International Association for the Study of the Liver, 2024, 44(3): 749-759.

[19] Nowak S, Mesropyan N, Faron A, et al. Detection of liver cirrhosis in standard T2-weighted MRI using deep transfer learning[J]. European Radiology, 2021, 31(11): 8807-8815.

[20] Mazumder N R, Enchakalody B, Zhang P, et al. Using Artificial Intelligence to Predict Cirrhosis From Computed Tomography Scans[J]. Clinical and Translational Gastroenterology, 2023, 14(10): e00616.

[21] Kanwal F, Taylor T J, Kramer J R, et al. Development, Validation, and Evaluation of a Simple Machine Learning Model to Predict Cirrhosis Mortality[J]. JAMA network open, 2020, 3(11): e2023780.

[22] Lin Y J, Chen R J, Tang J H, et al. Machine-Learning Monitoring System for Predicting Mortality Among Patients With Noncancer End-Stage Liver Disease:

Retrospective Study[J]. JMIR medical informatics, 2020, 8(10): e24305.

[23] Villanueva C, Albillos A, Genescà J, et al. β blockers to prevent decompensation of cirrhosis in patients with clinically significant portal hypertension (PREDESCI): a randomised, double-blind, placebo-controlled, multicentre trial[J]. Lancet (London, England), 2019, 393(10181): 1597-1608.

[24] Reiniš J, Petrenko O, Simbrunner B, et al. Assessment of portal hypertension severity using machine learning models in patients with compensated cirrhosis[J]. Journal of Hepatology, 2023, 78(2): 390-400.

[25] Liu F, Ning Z, Liu Y, et al. Development and validation of a radiomics signature for clinically significant portal hypertension in cirrhosis (CHESS1701): a prospective multicenter study[J]. EBioMedicine, 2018, 36: 151-158.

[26] Wang C, Huang Y, Liu C, et al. Diagnosis of Clinically Significant Portal Hypertension Using CT- and MRI-based Vascular Model[J]. Radiology, 2023, 307(2): e221648.

[27] H Z, X Z, B H, et al. Application of machine learning methods for predicting esophageal variceal bleeding in patients with cirrhosis[J]. European radiology, 2025, 35(3).

[28] Liu L, Nie Y, Liu Q, et al. A Practical Model for Predicting Esophageal Variceal Rebleeding in Patients with Hepatitis B-Associated Cirrhosis[J]. International Journal of Clinical Practice, 2023, 2023: 9701841.

[29] Baecker A, Liu X, La Vecchia C, et al. Worldwide incidence of hepatocellular carcinoma cases attributable to major risk factors[J]. European journal of cancer prevention: the official journal of the European Cancer Prevention Organisation (ECP), 2018, 27(3): 205-212.

[30] Finn R S, Qin S, Ikeda M, et al. Atezolizumab plus Bevacizumab in Unresectable Hepatocellular Carcinoma[J]. The New England Journal of Medicine, 2020, 382(20): 1894-1905.

[31] Fattovich G, Stroffolini T, Zagni I, et al. Hepatocellular carcinoma in cirrhosis: incidence and risk factors[J]. Gastroenterology, 2004, 127(5 Suppl 1): S35-50.

[32] Singal A G, Mukherjee A, Elmunzer B J, et al. Machine Learning Algorithms Outperform Conventional Regression Models in Predicting Development of Hepatocellular Carcinoma[J]. The American journal of gastroenterology, 2013,

108(11): 1723-1730.

[33] Kim H Y, Lampertico P, Nam J Y, et al. An artificial intelligence model to predict hepatocellular carcinoma risk in Korean and Caucasian patients with chronic hepatitis B[J]. Journal of Hepatology, 2022, 76(2): 311-318.

[34] Würstle S, Hapfelmeier A, Karapetyan S, et al. A Novel Machine Learning-Based Point-Score Model as a Non-Invasive Decision-Making Tool for Identifying Infected Ascites in Patients with Hydropic Decompensated Liver Cirrhosis: A Retrospective Multicentre Study[J]. Antibiotics (Basel, Switzerland), 2022, 11(11): 1610.

[35] Hatami B, Asadi F, Bayani A, et al. Machine learning-based system for prediction of ascites grades in patients with liver cirrhosis using laboratory and clinical data: design and implementation study[J]. Clinical Chemistry and Laboratory Medicine, 2022, 60(12): 1946-1954.

[36] Wang J Y, Zhang N P, Chi B R, et al. Prevalence of minimal hepatic encephalopathy and quality of life evaluations in hospitalized cirrhotic patients in China[J]. World Journal of Gastroenterology, 2013, 19(30): 4984-4991.

[37] Torre A, Córdova-Gallardo J, Martínez-Sánchez F D. Hepatic encephalopathy: risk identification and prophylaxis approaches[J]. Metabolic Brain Disease, 2025, 40(3): 138.

[38] Yang H, Li X, Cao H, et al. Using machine learning methods to predict hepatic encephalopathy in cirrhotic patients with unbalanced data[J]. Computer Methods and Programs in Biomedicine, 2021, 211: 106420.

[39] Shanmugha Priya R K, Suthendran D K. Hepatic encephalopathy detection using deep learning based optimized spiking neural network[J]. Measurement: Sensors, 2024, 32: 101061.

[40] Langer M M, Sichelschmidt S, Bauschen A, et al. Pathological neutrophil migration predicts adverse outcomes in hospitalized patients with liver cirrhosis[J]. Liver International: Official Journal of the International Association for the Study of the Liver, 2023, 43(4): 896-905.

[41] Pan Z, Lin J, Huo C, et al. Increased serum albumin corrected anion gap levels are associated with poor prognosis in septic patients with liver cirrhosis[J]. Scientific Reports, 2024, 14(1): 21510.

[42] Wang J, Chen X, Qin C, et al. Lactate-to-albumin ratio as a potential prognostic

predictor in patients with cirrhosis and sepsis: a retrospective cohort study[J]. BMC infectious diseases, 2025, 25(1): 223.

[43] Mathew B, Tripathi G, Gautam V, et al. Circulating bacterial peptides and linked metabolomic signatures are indicative of early mortality in pediatric cirrhosis[J]. Hepatology Communications, 2024, 8(6): e0440.

中英文术语和缩略语对照表

英文缩写	英文全名	中文全名
MIMIC-IV	Medical Information Mart for Intensive Care-IV	重症监护医疗信息集市 IV
eICU-CRD	eICU Collaborative Research Database	电子重症监护室合作研究数据库
ICU	Intensive Care Unit	重症监护室
SHAP	Shapley Additive Explanations	Shapley 可加性解释
PDP	Partial Dependence Plot	部份依赖图
HR	Hazard Ratio	风险比值
INR	International Normalized Ratio	国际标准化比值
MASLD	Metabolic Dysfunction-Associated Steatotic Liver Disease	代谢功能障碍相关脂肪性肝病
ICD	International Classification of Diseases	国际疾病分类
SOFA	Sequential Organ Failure Assessment	序贯器官衰竭评分
GCS	Glasgow Coma Scale	格拉斯哥昏迷评分
APSIII	Simplified Acute Physiology Score III	急性生理评分III
AIDS	Acquired Immunodeficiency Syndrome	获得性免疫缺陷综合征
SSE	Sum of Squared Errors	误差平方和
UMAP	Uniform Manifold Approximation and Projection	统一流形逼近与投影
SMD	Standardized Mean Difference	标准均值差
RFE	Recursive Feature Elimination	递归特征消除
LDA	Linear Discriminant Analysis	线性判别分析
QDA	Quadratic Discriminant Analysis	二次判别分析
NB	Naive Bayes	朴素贝叶斯
KNN	k-nearest neighbor	K 近邻
DT	Decision Tree	决策树
RF	Random Forest	随机森林
Xgboost	Extreme Gradient Boosting	极限梯度提升

英文缩写	英文全名	中文全名
SVM	Support Vector Machine	支持向量机
Macro AUC	Macro Area Under Curve	宏曲线下面积
CT	Computed Tomography	计算机断层扫描
AUC	Area Under Curve	曲线下面积
LASSO	Least Absolute Shrinkage And Selection Operator	最小绝对收缩和选择算子

攻读学位期间公开发表的文章

1.**Lin J**, Yin M, Liu L, Gao J, Yu C, Liu X, Xu C, Zhu J. The Development of a Prediction Model Based on Random Survival Forest for the Postoperative Prognosis of Pancreatic Cancer: A SEER-Based Study. Cancers (Basel). 2022 Sep 25;14(19):4667. doi: 10.3390/cancers14194667.

2.Liu L, **Lin J**, Yin M, Liu L, Gao J, Liu X, Zhu J, Wu A. Association of the fat mass index with hepatic steatosis and fibrosis: evidence from NHANES 2017-2018. Sci Rep. 2024 Mar 23;14(1):6943. doi: 10.1038/s41598-024-57388-1.

3.Yin M, **Lin J**, Wang Y, Liu Y, Zhang R, Duan W, Zhou Z, Zhu S, Gao J, Liu L, Liu X, Gu C, Huang Z, Xu X, Xu C, Zhu J. Development and validation of a multimodal model in predicting severe acute pancreatitis based on radiomics and deep learning. Int J Med Inform. 2024 Apr;184:105341. doi: 10.1016/j.ijmedinf.2024.105341.

4.**Lin J**, Zhu S, Gao X, Liu X, Xu C, Xu Z, Zhu J. Evaluation of super resolution technology for digestive endoscopic images. Heliyon. 2024 Oct 3;10(19):e38920. doi: 10.1016/j.heliyon.2024.e38920.

5.**Lin J**, Zhu S, Yin M, Xue H, Liu L, Liu X, Liu L, Xu C, Zhu J. Few-shot learning for the classification of intestinal tuberculosis and Crohn's disease on endoscopic images: A novel learn-to-learn framework. Heliyon. 2024 Feb 16;10(4):e26559. doi: 10.1016/j.heliyon.2024.e26559.

6.Yin M, **Lin J**, Liu L, Gao J, Xu W, Yu C, Qu S, Liu X, Qian L, Xu C, Zhu J. Development of a Deep Learning Model for Malignant Small Bowel Tumors Survival: A SEER-Based Study. Diagnostics (Basel). 2022 May 17;12(5):1247. doi: 10.3390/diagnostics12051247.

7.Liu L, **Lin J**, Liu L, Gao J, Xu G, Yin M, Liu X, Wu A, Zhu J. Automated machine learning models for nonalcoholic fatty liver disease assessed by controlled attenuation parameter from the NHANES 2017-2020. Digit Health. 2024 Aug 7;10:20552076241272535. doi: 10.1177/20552076241272535.

8.Shi Y, **Lin J**, Zhu J, Gao J, Liu L, Yin M, Yu C, Liu X, Wang Y, Xu C. Predicting the Recurrence of Common Bile Duct Stones After ERCP Treatment with Automated Machine Learning Algorithms. Dig Dis Sci. 2023 Jul;68(7):2866-2877. doi:

10.1007/s10620-023-07949-7. Epub 2023 May 9.

9.Gao X, **Lin J**, Qu C, Wang C, Wu A, Zhu J, Xu C. Computer-aided diagnostic system with automated deep learning method based on the AutoGluon framework improved the diagnostic accuracy of early esophageal cancer. J Gastrointest Oncol. 2024 Apr 30;15(2):535-543. doi: 10.21037/jgo-24-158. Epub 2024 Apr 29.

10.He Y, **Lin J**, Zhu S, Zhu J, Xu Z. Deep learning in the radiologic diagnosis of osteoporosis: a literature review. J Int Med Res. 2024 Apr;52(4):3000605241244754. doi: 10.1177/03000605241244754.

11.**Lin J**, Yang J, Yin M, Tang Y, Chen L, Xu C, Zhu S, Gao J, Liu L, Liu X, Gu C, Huang Z, Wei Y, Zhu J. Development and Validation of Multimodal Models to Predict the 30-Day Mortality of ICU Patients Based on Clinical Parameters and Chest X-Rays. J Imaging Inform Med. 2024 Aug;37(4):1312-1322. doi: 10.1007/s10278-024-01066-1.

致 谢

岁月不居，时节如流。三年一瞬，回首过往，百感交集，难以尽述。

“学贵得师”，衷心感谢我的恩师——**朱锦舟老师**。他是我科研上的领路人，生活中的好兄长。无论是研究的困惑，亦或是人生的迷茫，朱老师始终倾尽所能。“饮其流者怀其源”，师恩难忘，铭感五内。

“亦贵得友”，感谢求学路上一路同行的挚友。感谢**殷民月**，**高静雯**，**刘璐**各位师姐，在这三年中给予我真诚的关心与鼓励。感谢**朱世祺**，**刘力赫**师弟师妹科研和临床中的鼎力协助与陪伴。

感谢我的母亲**林金秀**女士，无条件的爱和支持，鼓励我不断前进，是我最坚强的后盾。

感谢三年来的自己，没有放弃最初的那个似乎遥不可及的梦想。

但行好事，莫问前程！